

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
TRƯỜNG CÔNG NGHỆ SỐ VÀ TRÍ TUỆ NHÂN TẠO



PHÂN LOẠI BỆNH ĐÁI THÁO ĐƯỜNG TỪ
ẢNH ĐÁY MẮT

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành: Công nghệ thông tin

Mã số ngành: 7480201

Tháng 6 - năm 2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
TRƯỜNG CÔNG NGHỆ SỐ VÀ TRÍ TUỆ NHÂN TẠO

NGUYỄN THÀNH NGUYỄN

MSSV: 225255

PHÂN LOẠI BỆNH ĐÁI THÁO ĐƯỜNG TỪ
ẢNH ĐÁY MẮT

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành: Công nghệ thông tin

Mã số ngành: 7480201

GIẢNG VIÊN HƯỚNG DẪN

ThS. TRẦN VĂN THIỆN

Tháng 6 - năm 2026

CHẤP THUẬN HỘI ĐỒNG

Khóa luận “Phân loại bệnh đái tháo đường từ ảnh đáy mắt”, do sinh viên Nguyễn Thành Nguyên thực hiện dưới sự hướng dẫn của Giảng viên Trần Văn Thiện. Khóa luận tốt nghiệp đã báo cáo và được hội đồng chấm Khóa luận thông qua ngày ... tháng ... năm 2026.

Ủy viên
(Ký tên)

Thư ký
(Ký tên)

Phản biện 1
(Ký tên)

Phản biện 2
(Ký tên)

Cán bộ hướng dẫn
(Ký tên)

Chủ tịch Hội đồng
(Ký tên)

LỜI CẢM TẠ

Em xin bày tỏ lòng biết ơn sâu sắc đến Quý Thầy/Cô thuộc Khoa Công nghệ Thông tin, Trường Đại học Nam Cần Thơ đã tận tình giảng dạy, truyền đạt kiến thức chuyên môn và tạo điều kiện thuận lợi cho em trong suốt quá trình học tập và thực hiện Luận văn.

Đặc biệt, em xin gửi lời cảm ơn chân thành đến Thầy Trần Văn Thiện – giảng viên hướng dẫn, người đã trực tiếp định hướng, góp ý và hỗ trợ em trong suốt quá trình nghiên cứu và triển khai đề tài. Những ý kiến đóng góp quý báu của Thầy là cơ sở quan trọng giúp em hoàn thiện nội dung và nâng cao chất lượng của đồ án.

Thông qua quá trình thực hiện Luận văn, em đã có cơ hội vận dụng các kiến thức đã học vào thực tiễn, đồng thời tích lũy thêm kinh nghiệm trong việc xây dựng và phát triển một hệ thống ứng dụng trí tuệ nhân tạo. Đây là nền tảng quan trọng giúp em định hướng và phát triển trong học tập cũng như công việc trong tương lai.

Mặc dù đã có nhiều cố gắng, nhưng do hạn chế về thời gian và kinh nghiệm, luận văn khó tránh khỏi những thiếu sót. Em rất mong nhận được sự đóng góp ý kiến từ Quý Thầy/Cô để đề tài được hoàn thiện hơn.

Em xin chân thành cảm ơn!

Cần Thơ, ngày tháng năm 2026

Người thực hiện

NGUYỄN THÀNH NGUYỄN

LỜI CAM KẾT

Em xin cam kết rằng báo cáo Luận văn này là kết quả của quá trình học tập, nghiên cứu và thực hiện độc lập của bản thân em dưới sự hướng dẫn của giảng viên. Toàn bộ nội dung trong báo cáo được xây dựng dựa trên kiến thức đã học, tài liệu tham khảo có chọn lọc và quá trình triển khai thực tế của đề tài.

Em cam đoan rằng các kết quả, phân tích và nội dung trình bày trong báo cáo là trung thực, chính xác và chưa từng được công bố hoặc sử dụng trong bất kỳ công trình hay báo cáo nào trước đây.

Em xin hoàn toàn chịu trách nhiệm về tính trung thực, tính chính xác cũng như tính nguyên bản của toàn bộ nội dung trong báo cáo này.

Em xin chân thành cảm ơn!

Cần Thơ, ngày tháng năm 2026

Người thực hiện

NGUYỄN THÀNH NGUYỄN

TÓM TẮT

Bệnh võng mạc đái tháo đường là một biến chứng nguy hiểm của bệnh đái tháo đường, có thể gây suy giảm thị lực nếu không được phát hiện và theo dõi kịp thời. Đề tài này tập trung xây dựng mô hình học sâu hỗ trợ phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt theo 5 mức độ: No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Tập dữ liệu được sử dụng là APTOS 2019 Blindness Detection. Ảnh đầu vào được tiền xử lý bằng các bước cắt vùng viền đen, tăng cường tương phản bằng CLAHE, thay đổi kích thước về 320×320 và chuẩn hóa trước khi đưa vào mô hình. Hai mô hình DenseNet121 và EfficientNetB3 được xây dựng, huấn luyện riêng, sau đó kết hợp xác suất đầu ra bằng phương pháp ensemble weighted average với trọng số 0,45 cho DenseNet121 và 0,55 cho EfficientNetB3.

Kết quả thực nghiệm cho thấy mô hình ensemble đạt accuracy 84,73%, Quadratic Weighted Kappa 0,9042, macro-F1 0,7066 và AUC 0,9522 trên tập kiểm tra. So với từng mô hình đơn lẻ, phương pháp ensemble cho kết quả tốt hơn ở nhiều chỉ số quan trọng, đặc biệt là QWK, macro-F1 và AUC. Bên cạnh mô hình phân loại, đề tài còn tích hợp mô hình vào hệ thống web thử nghiệm, cho phép người dùng tải ảnh đáy mắt, xem kết quả dự đoán, xác suất từng lớp, ảnh gốc, ảnh sau tiền xử lý và heatmap giải thích. Hệ thống cũng bổ sung cảnh báo khi mô hình có độ tin cậy thấp hoặc khi xác suất giữa các lớp bệnh lân cận gần nhau. Kết quả của đề tài cho thấy mô hình học sâu có thể hỗ trợ phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt trong phạm vi nghiên cứu, đồng thời tạo nền tảng để phát triển các hệ thống hỗ trợ sàng lọc trong tương lai.

MỤC LỤC

CHƯƠNG 1 MỞ ĐẦU	1
1.1. Lý do chọn đề tài.....	1
1.2. Mục tiêu nghiên cứu.....	2
1.2.1. Mục tiêu tổng quát.....	2
1.2.2. Mục tiêu cụ thể.....	2
1.3. Đối tượng và phạm vi nghiên cứu.....	3
1.3.1. Đối tượng nghiên cứu.....	3
1.3.2. Phạm vi nghiên cứu.....	4
1.4. Phương pháp nghiên cứu.....	5
1.5. Ý nghĩa của đề tài.....	6
1.5.1. Ý nghĩa khoa học.....	6
1.5.2. Ý nghĩa thực tiễn.....	7
1.6. Đóng góp của đề tài	8
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN.....	10
2.1. Tổng quan về bệnh võng mạc đái tháo đường.....	10
2.2. Tổng quan về học sâu trong xử lý ảnh y tế.....	11
2.3. Các mô hình học sâu sử dụng trong đề tài.....	11
2.4. Phương pháp ensemble learning.....	13
2.5. Tiền xử lý ảnh đáy mắt.....	14
2.6. Các chỉ số đánh giá mô hình.....	15
2.7. Giải thích mô hình AI trong ảnh y tế.....	16
2.8. Các nghiên cứu liên quan trong 5 năm gần đây.....	17
2.9. Định hướng phương pháp của đề tài.....	21
CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG HỖ TRỢ DỰ ĐOÁN.....	23
3.1. Tổng quan hệ thống đề xuất.....	23
3.2. Yêu cầu hệ thống.....	23
3.2.1. Yêu cầu chức năng.....	23
3.2.2. Yêu cầu phi chức năng.....	24

3.3. Quy trình hoạt động của hệ thống.....	25
3.4. Kiến trúc tổng thể của hệ thống.....	26
3.5. Thiết kế dữ liệu đầu vào và kết quả đầu ra.....	28
3.6. Cảnh báo y tế và giới hạn sử dụng của hệ thống.....	29
CHƯƠNG 4. XÂY DỰNG MÔ HÌNH PHÂN LOẠI BỆNH VÕNG MẠC ĐÁI THÁO ĐƯỜNG.....	31
4.1. Tập dữ liệu sử dụng trong đề tài.....	31
4.1.1. Giới thiệu tập dữ liệu APTOS 2019.....	31
4.1.2. Cấu trúc dữ liệu.....	31
4.1.3. Phân bố các lớp bệnh.....	32
4.2. Quy trình tiền xử lý dữ liệu.....	32
4.3. Xây dựng mô hình DenseNet121.....	34
4.4. Xây dựng mô hình EfficientNetB3.....	35
4.5. Kết hợp mô hình bằng ensemble weighted average.....	36
4.6. Sinh heatmap giải thích kết quả dự đoán.....	38
4.7. Lưu mô hình và tích hợp vào hệ thống web.....	39
CHƯƠNG 5. THỰC NGHIỆM, ĐÁNH GIÁ VÀ TRIỂN KHAI HỆ THỐNG.....	40
5.1. Môi trường và cấu hình thực nghiệm.....	40
5.2. Kết quả huấn luyện và đánh giá mô hình.....	41
5.3. Phân tích kết quả phân loại.....	43
5.5. Kết quả triển khai hệ thống web.....	46
5.6. Nhận xét chung về kết quả thực nghiệm.....	49
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	51
6.1. Kết quả đạt được.....	51
6.2. Hạn chế của đề tài.....	51
6.3. Hướng phát triển trong tương lai.....	52
TÀI LIỆU THAM KHẢO.....	54

DANH MỤC BIỂU BẢNG

<u>Bảng 2. 1. Các nghiên cứu liên quan</u>	19
Bảng 3. 1. Các yêu cầu chức năng chính của hệ thống.....	24
Bảng 3. 2. Các yêu cầu phi chức năng chính của hệ thống.....	25
Bảng 3. 3. Các thành phần dữ liệu đầu vào và kết quả đầu ra của hệ thống.....	29
Bảng 3. 4. Một số trường hợp cảnh báo được sử dụng trong hệ thống.....	30
Bảng 4. 1. Ý nghĩa các nhãn trong tập dữ liệu APTOS 2019.....	32
Bảng 5. 1. Môi trường và cấu hình thực nghiệm chính của đề tài.....	41
Bảng 5. 2. Kết quả đánh giá của DenseNet121, EfficientNetB3 và mô hình ensemble trên tập kiểm tra.....	42
Bảng 5. 3. Classification report của mô hình ensemble trên tập kiểm tra.....	44
Bảng 5. 4. Ma trận nhầm lẫn của mô hình ensemble trên tập kiểm tra.....	44

DANH MỤC HÌNH

Hình 3. 1. Kiến trúc tổng thể hệ thống	27
Hình 4. 1. Ảnh minh họa ảnh đáy mắt thuộc 5 mức độ bệnh.....	32
Hình 4. 2. Quy trình tiền xử lý ảnh đáy mắt.....	33
Hình 4. 3. Sơ đồ DenseNet121	34
Hình 4. 4. Sơ đồ EfficientNetB3.....	35
Hình 4. 5. Quy trình kết hợp mô hình bằng ensemble weighted average.....	37
Hình 4. 6. Sinh heatmap giải thích kết quả dự đoán.....	38
Hình 5. 1. Confusion matrix của mô hình ensemble trên tập kiểm tra.....	45
Hình 5. 2. Giao diện tải ảnh đáy mắt của hệ thống.....	47
Hình 5. 3. Giao diện hiển thị kết quả dự đoán, xác suất, ảnh tiền xử lý và heatmap.....	48

DANH MỤC TỪ VIẾT TẮT

AI	:	Artificial Intelligence
API	:	Application Programming Interface
APTOS	:	Asia Pacific Tele-Ophthalmology Society
AUC	:	Area Under the Curve
CLAHE	:	Contrast Limited Adaptive Histogram Equalization
CNN	:	Convolutional Neural Network
CPU	:	Central Processing Unit
DL	:	Deep Learning
DR	:	Diabetic Retinopathy
ESRGAN	:	Enhanced Super-Resolution Generative Adversarial Network
F1-score	:	F1-score
FN	:	False Negative
FP	:	False Positive
GPU	:	Graphics Processing Unit
IG	:	Integrated Gradients
IDF	:	International Diabetes Federation
IDRiD	:	Indian Diabetic Retinopathy Image Dataset
QWK	:	Quadratic Weighted Kappa
RAM	:	Random Access Memory
ROC	:	Receiver Operating Characteristic
TN	:	True Negative
TP	:	True Positive
WHO	:	World Health Organization

XAI : Explainable Artificial Intelligence

CHƯƠNG 1

MỞ ĐẦU

1.1. Lý do chọn đề tài

Bệnh đái tháo đường là một bệnh mạn tính phổ biến và có thể gây ra nhiều biến chứng nghiêm trọng nếu không được theo dõi, kiểm soát và điều trị phù hợp. Trong số các biến chứng của bệnh đái tháo đường, bệnh võng mạc đái tháo đường là một biến chứng đáng quan tâm vì ảnh hưởng trực tiếp đến thị lực của người bệnh. Khi tình trạng tăng đường huyết kéo dài làm tổn thương các mạch máu nhỏ tại võng mạc, người bệnh có thể xuất hiện các dấu hiệu bất thường như vi phình mạch, xuất huyết, xuất tiết, phù hoàng điểm hoặc tăng sinh mạch máu bất thường. Nếu không được phát hiện và can thiệp kịp thời, bệnh có thể tiến triển đến các giai đoạn nặng hơn và làm tăng nguy cơ suy giảm thị lực [1], [5], [6].

Việc sàng lọc bệnh võng mạc đái tháo đường có vai trò quan trọng trong phát hiện sớm các trường hợp có nguy cơ tổn thương thị lực. Theo Tổ chức Y tế Thế giới, sàng lọc bệnh võng mạc đái tháo đường kết hợp với điều trị kịp thời là một trong những biện pháp cần thiết nhằm giảm nguy cơ suy giảm thị lực và mù lòa ở người mắc bệnh đái tháo đường [1], [2]. Tuy nhiên, trong thực tế, việc đánh giá ảnh đáy mắt thường cần đến bác sĩ chuyên khoa mắt hoặc nhân sự có kinh nghiệm đọc ảnh. Quá trình này có thể bị ảnh hưởng bởi số lượng bệnh nhân cần sàng lọc, chất lượng ảnh đầu vào, điều kiện thiết bị, thời gian xử lý và sự chênh lệch về nguồn lực y tế giữa các khu vực.

Anh đáy mắt là nguồn dữ liệu quan trọng trong đánh giá bệnh võng mạc đái tháo đường. Thông qua ảnh đáy mắt, có thể quan sát được gai thị, hoàng điểm, hệ thống mạch máu võng mạc và một số dấu hiệu bất thường liên quan đến tổn thương do đái tháo đường. Với sự phát triển của trí tuệ nhân tạo, đặc biệt là học sâu trong xử lý ảnh, các mô hình mạng nơ-ron tích chập đã được ứng dụng rộng rãi trong nhiều bài toán phân tích ảnh y tế. Trong lĩnh vực bệnh võng mạc đái tháo đường, nhiều nghiên cứu đã chứng minh tiềm năng của mô hình học sâu trong việc phát hiện và phân loại bệnh từ ảnh đáy mắt, qua đó hỗ trợ quá trình sàng lọc và giảm tải cho quy trình đánh giá thủ công [13], [36], [37].

Tại Việt Nam, bệnh đái tháo đường cũng là một vấn đề cần được quan tâm trong chăm sóc sức khỏe cộng đồng. Theo dữ liệu của Liên đoàn Đái tháo đường Quốc tế, số người trưởng thành từ 20 đến 79 tuổi mắc đái tháo đường tại Việt Nam năm 2024 ước tính khoảng 2,5 triệu người [3]. Điều này cho thấy nhu cầu theo dõi, phát hiện sớm và hỗ trợ sàng lọc các biến chứng liên quan đến bệnh đái tháo đường là cần thiết. Trong đó, việc xây dựng một hệ thống hỗ trợ phân loại bệnh võng mạc đái tháo đường

từ ảnh đáy mắt có thể góp phần hỗ trợ quá trình sàng lọc ban đầu, đặc biệt trong bối cảnh cần một công cụ có khả năng xử lý nhanh, nhất quán và dễ triển khai dưới dạng phần mềm.

Từ những lý do trên, đề tài “Phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt” được lựa chọn nhằm xây dựng một hệ thống hỗ trợ phân loại 5 mức độ bệnh võng mạc đái tháo đường dựa trên ảnh fundus. Đề tài sử dụng hai mô hình học sâu DenseNet121 và EfficientNetB3 để khai thác đặc trưng ảnh, sau đó kết hợp kết quả dự đoán bằng phương pháp ensemble weighted average nhằm tận dụng ưu điểm của từng mô hình. Bên cạnh kết quả phân loại, hệ thống còn hiển thị xác suất dự đoán, ảnh sau tiền xử lý, heatmap giải thích và cảnh báo khi mô hình chưa chắc chắn giữa các mức bệnh lân cận. Hệ thống được xây dựng với mục tiêu hỗ trợ tham khảo và sàng lọc ban đầu, không thay thế kết luận chẩn đoán của bác sĩ chuyên khoa.

1.2. Mục tiêu nghiên cứu

1.2.1. Mục tiêu tổng quát

Mục tiêu tổng quát của đề tài là xây dựng hệ thống hỗ trợ phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt bằng mô hình học sâu. Hệ thống hướng đến việc hỗ trợ nhận diện 5 mức độ bệnh võng mạc đái tháo đường, bao gồm: không mắc bệnh, mức độ nhẹ, mức độ trung bình, mức độ nặng và bệnh võng mạc tăng sinh. Kết quả của hệ thống được sử dụng với vai trò hỗ trợ tham khảo trong quá trình sàng lọc ban đầu, không thay thế cho kết luận chẩn đoán của bác sĩ chuyên khoa.

Đề tài tập trung kết hợp giữa mô hình học sâu và ứng dụng web nhằm tạo ra một hệ thống có khả năng tiếp nhận ảnh đầu vào, xử lý ảnh, dự đoán mức độ bệnh, hiển thị xác suất dự đoán và cung cấp hình ảnh trực quan hỗ trợ giải thích kết quả. Qua đó, hệ thống không chỉ đưa ra nhãn phân loại cuối cùng mà còn giúp người dùng quan sát được quá trình xử lý ảnh và vùng ảnh có ảnh hưởng đến quyết định của mô hình.

1.2.2. Mục tiêu cụ thể

Để đạt được mục tiêu tổng quát, đề tài tập trung thực hiện các mục tiêu cụ thể sau:

Thứ nhất, tìm hiểu cơ sở lý thuyết về bệnh võng mạc đái tháo đường, ảnh đáy mắt và các mức độ phân loại bệnh. Nội dung này giúp xác định rõ bài toán cần giải quyết, đặc điểm dữ liệu đầu vào và ý nghĩa của từng lớp bệnh trong quá trình phân loại.

Thứ hai, xây dựng quy trình tiền xử lý ảnh đáy mắt trước khi đưa vào mô hình học sâu. Quy trình tiền xử lý bao gồm loại bỏ vùng viền đen không cần thiết, tăng cường tương phản cục bộ bằng CLAHE, thay đổi kích thước ảnh về 320×320 và

chuẩn hóa ảnh phù hợp với từng mô hình. Mục tiêu của bước này là làm cho dữ liệu đầu vào ổn định hơn và giúp mô hình tập trung vào vùng võng mạc có ý nghĩa.

Thứ ba, huấn luyện và đánh giá hai mô hình học sâu DenseNet121 và EfficientNetB3 cho bài toán phân loại 5 mức độ bệnh võng mạc đái tháo đường. Hai mô hình này được lựa chọn nhằm khai thác các đặc trưng ảnh theo những kiến trúc khác nhau, từ đó tạo cơ sở cho việc kết hợp kết quả dự đoán ở bước sau.

Thứ tư, xây dựng phương pháp kết hợp mô hình bằng ensemble weighted average. Trong đề tài, kết quả dự đoán cuối cùng được tính bằng cách kết hợp xác suất đầu ra của EfficientNetB3 và DenseNet121 với trọng số tương ứng. Mục tiêu của phương pháp này là tận dụng ưu điểm của từng mô hình đơn lẻ và cải thiện độ ổn định của kết quả phân loại.

Thứ năm, đánh giá hiệu quả mô hình bằng các chỉ số phù hợp với bài toán phân loại ảnh y tế, bao gồm accuracy, precision, recall, F1-score, macro-F1, weighted-F1, Quadratic Weighted Kappa, AUC và confusion matrix. Việc sử dụng nhiều chỉ số đánh giá giúp nhận xét toàn diện hơn về hiệu quả của mô hình, đặc biệt trong bối cảnh dữ liệu có sự mất cân bằng giữa các lớp.

Thứ sáu, phân tích điểm mạnh và hạn chế của mô hình, đặc biệt là khả năng phân biệt giữa các lớp bệnh lân cận. Trong đề tài này, lớp Severe DR được chú ý riêng do có số lượng mẫu ít hơn và dễ bị nhầm lẫn với lớp Moderate DR. Vì vậy, hệ thống được bổ sung cơ chế cảnh báo khi mô hình chưa chắc chắn giữa hai mức bệnh này.

Thứ bảy, xây dựng ứng dụng web cho phép người dùng upload ảnh đáy mắt và nhận kết quả dự đoán. Giao diện hệ thống cần hiển thị được ảnh gốc, ảnh sau tiền xử lý, nhãn dự đoán, xác suất từng lớp, kết quả từng mô hình, kết quả ensemble, heatmap giải thích và báo cáo kết quả. Đây là phần giúp mô hình học sâu được triển khai thành một hệ thống phần mềm hoàn chỉnh, dễ sử dụng trong quá trình minh họa và thử nghiệm.

1.3. Đối tượng và phạm vi nghiên cứu

1.3.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu chính của đề tài là ảnh đáy mắt được sử dụng trong bài toán phân loại bệnh võng mạc đái tháo đường. Ảnh đáy mắt là loại ảnh cho phép quan sát các thành phần quan trọng của võng mạc như gai thị, hệ thống mạch máu, hoàng điểm và các dấu hiệu bất thường liên quan đến tổn thương võng mạc. Trong bài toán này, ảnh đáy mắt được sử dụng làm dữ liệu đầu vào cho mô hình học sâu để dự đoán mức độ bệnh.

Bên cạnh dữ liệu ảnh, đề tài còn nghiên cứu các mức độ bệnh võng mạc đái tháo đường theo bài toán phân loại 5 lớp, bao gồm: không mắc bệnh võng mạc đái tháo

đường, bệnh mức độ nhẹ, bệnh mức độ trung bình, bệnh mức độ nặng và bệnh võng mạc đái tháo đường tăng sinh. Việc phân chia thành 5 mức độ giúp mô hình không chỉ nhận biết ảnh có bệnh hay không có bệnh, mà còn hỗ trợ đánh giá mức độ tiến triển của bệnh trên ảnh đáy mắt [5], [9].

Ngoài ra, đề tài tập trung nghiên cứu và ứng dụng các mô hình học sâu trong phân loại ảnh y tế, cụ thể là hai mô hình DenseNet121 và EfficientNetB3. Hai mô hình này được lựa chọn để trích xuất đặc trưng từ ảnh đáy mắt và dự đoán xác suất thuộc về từng lớp bệnh. Kết quả của hai mô hình sau đó được kết hợp bằng phương pháp ensemble weighted average nhằm tạo ra kết quả dự đoán cuối cùng.

Đối tượng nghiên cứu của đề tài cũng bao gồm hệ thống phần mềm hỗ trợ sử dụng mô hình đã huấn luyện. Hệ thống này cho phép người dùng tải ảnh đáy mắt lên, thực hiện tiền xử lý ảnh, chạy mô hình dự đoán, hiển thị kết quả phân loại, xác suất dự đoán, ảnh sau tiền xử lý và heatmap giải thích. Nhờ đó, mô hình học sâu không chỉ dừng lại ở giai đoạn thực nghiệm mà còn được triển khai thành một ứng dụng web minh họa có khả năng sử dụng trực tiếp.

1.3.2. Phạm vi nghiên cứu

Phạm vi nghiên cứu của đề tài được giới hạn trong bài toán phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt. Đề tài tập trung vào phân loại ảnh thành 5 lớp tương ứng với các mức độ bệnh, bao gồm: No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Đây là bài toán phân loại đa lớp, trong đó mỗi ảnh đầu vào được mô hình dự đoán thuộc một trong năm mức độ bệnh.

Về dữ liệu, đề tài sử dụng tập dữ liệu APTOS 2019 Blindness Detection làm nguồn dữ liệu chính cho quá trình huấn luyện và đánh giá mô hình [9]. Đây là tập dữ liệu gồm ảnh đáy mắt đã được gán nhãn theo các mức độ bệnh võng mạc đái tháo đường. Trong quá trình thực hiện, dữ liệu được chia thành các tập huấn luyện, kiểm định và kiểm tra nhằm phục vụ việc huấn luyện, lựa chọn mô hình và đánh giá kết quả.

Về phương pháp, đề tài tập trung vào hướng tiếp cận học sâu dựa trên mạng nơ-ron tích chập CNN. Cụ thể, hai kiến trúc CNN là DenseNet121 và EfficientNetB3 được sử dụng để trích xuất đặc trưng và phân loại ảnh đáy mắt. Sau đó, kết quả dự đoán của hai mô hình được kết hợp bằng phương pháp ensemble weighted average nhằm tạo ra kết quả phân loại cuối cùng ổn định hơn.

Về tiền xử lý ảnh, đề tài chỉ sử dụng các bước xử lý cơ bản và an toàn đối với ảnh y tế, bao gồm loại bỏ vùng viền đen, tăng cường tương phản cục bộ bằng CLAHE, thay đổi kích thước ảnh về 320×320 và chuẩn hóa ảnh theo yêu cầu đầu vào của từng mô hình.

Về chức năng hệ thống, đề tài xây dựng một ứng dụng web ở mức minh họa và thử nghiệm. Hệ thống cho phép người dùng upload ảnh đáy mắt, nhận kết quả dự đoán, xem xác suất của từng lớp, xem ảnh sau tiền xử lý, xem heatmap giải thích và tải báo cáo kết quả. Hệ thống không được xây dựng như một phần mềm y tế hoàn chỉnh để triển khai lâm sàng, mà chỉ đóng vai trò là hệ thống hỗ trợ tham khảo trong phạm vi nghiên cứu học thuật.

Về giới hạn chuyên môn, đề tài không thực hiện phân đoạn tổn thương võng mạc, không định vị chính xác từng loại tổn thương như vi phình mạch, xuất huyết hoặc xuất tiết, và không thay thế chẩn đoán của bác sĩ chuyên khoa. Heatmap trong hệ thống chỉ được sử dụng để trực quan hóa vùng ảnh có ảnh hưởng đến quyết định của mô hình, không được xem là kết quả phân đoạn tổn thương y khoa.

1.4. Phương pháp nghiên cứu

Để thực hiện đề tài “Phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt”, luận văn sử dụng kết hợp nhiều phương pháp nghiên cứu phù hợp với đặc thù của bài toán trí tuệ nhân tạo trong xử lý ảnh y tế và xây dựng hệ thống phần mềm. Các phương pháp chính được sử dụng bao gồm: phương pháp nghiên cứu tài liệu, phương pháp phân tích và tổng hợp, phương pháp thực nghiệm, phương pháp mô hình hóa, phương pháp đánh giá định lượng và phương pháp xây dựng, kiểm thử hệ thống.

Trước hết, đề tài sử dụng phương pháp nghiên cứu tài liệu nhằm tìm hiểu cơ sở lý thuyết liên quan đến bệnh võng mạc đái tháo đường, ảnh đáy mắt, mạng nơ-ron tích chập và các nghiên cứu ứng dụng học sâu trong phân loại bệnh võng mạc đái tháo đường. Thông qua việc khảo sát tài liệu, đề tài xác định được đặc điểm của bài toán, các mức độ bệnh cần phân loại, các mô hình học sâu thường được sử dụng và các chỉ số đánh giá phù hợp với bài toán phân loại ảnh y tế. Phương pháp này cũng được sử dụng để tổng hợp các nghiên cứu liên quan trong những năm gần đây, từ đó làm cơ sở lựa chọn hướng tiếp cận của đề tài.

Bên cạnh đó, phương pháp phân tích và tổng hợp được sử dụng để phân tích yêu cầu của bài toán và tổng hợp thành quy trình xử lý phù hợp. Cụ thể, đề tài phân tích đặc điểm của ảnh đáy mắt, đặc điểm mất cân bằng dữ liệu giữa các lớp bệnh, yêu cầu đầu vào của mô hình học sâu và yêu cầu hiển thị kết quả trên hệ thống web. Từ các phân tích này, đề tài tổng hợp thành pipeline xử lý gồm các bước: tiền xử lý ảnh, huấn luyện mô hình CNN, kết hợp kết quả dự đoán, đánh giá mô hình và triển khai lên ứng dụng web.

Phương pháp thực nghiệm được sử dụng trong quá trình huấn luyện và kiểm tra mô hình. Đề tài sử dụng tập dữ liệu APTOS 2019 Blindness Detection làm dữ liệu chính cho thực nghiệm [9]. Dữ liệu được chia thành các tập huấn luyện, kiểm định và kiểm tra để phục vụ quá trình xây dựng mô hình và đánh giá kết quả. Trong quá trình

thực nghiệm, hai mô hình CNN là DenseNet121 và EfficientNetB3 được huấn luyện cho bài toán phân loại 5 mức độ bệnh võng mạc đái tháo đường. Ngoài ra, đề tài cũng thực hiện các bước tiền xử lý ảnh như loại bỏ viền đen, tăng cường tương phản bằng CLAHE, thay đổi kích thước ảnh và chuẩn hóa ảnh trước khi đưa vào mô hình.

Phương pháp mô hình hóa được sử dụng để biểu diễn kiến trúc và luồng xử lý của hệ thống. Trong đề tài, các thành phần chính như dữ liệu đầu vào, khối tiền xử lý, mô hình DenseNet121, mô hình EfficientNetB3, khối ensemble, backend, frontend và phần hiển thị kết quả được mô hình hóa thành sơ đồ tổng thể. Việc mô hình hóa giúp trình bày rõ cách hệ thống hoạt động, mối liên hệ giữa các thành phần và quá trình dữ liệu được xử lý từ lúc người dùng upload ảnh đến khi hệ thống trả về kết quả dự đoán.

Phương pháp đánh giá định lượng được sử dụng để đánh giá hiệu quả của các mô hình đã huấn luyện. Các chỉ số được sử dụng bao gồm accuracy, precision, recall, F1-score, macro-F1, weighted-F1, Quadratic Weighted Kappa, AUC và confusion matrix. Việc sử dụng nhiều chỉ số đánh giá giúp phản ánh kết quả mô hình ở nhiều góc độ khác nhau, đặc biệt trong bối cảnh dữ liệu có sự mất cân bằng giữa các lớp bệnh. Ngoài đánh giá tổng thể, đề tài cũng phân tích kết quả theo từng lớp để nhận diện các lớp còn khó phân loại, trong đó chú ý đến sự nhầm lẫn giữa Moderate DR và Severe DR.

Phương pháp xây dựng và kiểm thử hệ thống được sử dụng trong giai đoạn triển khai mô hình vào ứng dụng web. Hệ thống được xây dựng gồm backend xử lý ảnh và chạy mô hình, frontend cho phép người dùng upload ảnh và xem kết quả. Sau khi xây dựng, hệ thống được kiểm thử thông qua các chức năng chính như kiểm tra trạng thái server, upload ảnh hợp lệ, xử lý ảnh đầu vào, hiển thị kết quả dự đoán, hiển thị xác suất từng lớp, hiển thị ảnh sau tiền xử lý, heatmap giải thích và sinh báo cáo kết quả. Phương pháp này giúp đảm bảo mô hình không chỉ hoạt động trong môi trường huấn luyện mà còn có thể được tích hợp vào một phần mềm minh họa hoàn chỉnh.

1.5. Ý nghĩa của đề tài

1.5.1. Ý nghĩa khoa học

Đề tài có ý nghĩa khoa học trong việc nghiên cứu và ứng dụng mô hình học sâu vào bài toán phân loại ảnh y tế, cụ thể là phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt. Thông qua việc sử dụng hai kiến trúc mạng nơ-ron tích chập là DenseNet121 và EfficientNetB3, đề tài khai thác khả năng tự động học đặc trưng ảnh của các mô hình CNN trong nhận diện các mức độ bệnh khác nhau. Bên cạnh việc huấn luyện từng mô hình riêng lẻ, đề tài còn áp dụng phương pháp ensemble weighted average để kết hợp kết quả dự đoán của hai mô hình. Việc kết hợp này giúp đánh giá khả năng cải thiện kết quả phân loại khi sử dụng nhiều mô hình CNN thay vì chỉ dựa

vào một mô hình đơn. Đây là một hướng tiếp cận phù hợp trong các bài toán phân loại ảnh y tế, nơi dữ liệu thường có độ phức tạp cao và sự khác biệt giữa các lớp bệnh có thể không rõ ràng. Ngoài ra, đề tài còn góp phần làm rõ vai trò của các bước tiền xử lý ảnh trong bài toán phân loại ảnh đáy mắt. Các bước như loại bỏ viền đen, tăng cường tương phản bằng CLAHE, thay đổi kích thước ảnh và chuẩn hóa dữ liệu giúp tạo ra đầu vào ổn định hơn cho mô hình. Việc phân tích kết quả theo nhiều chỉ số như accuracy, macro-F1, Quadratic Weighted Kappa, AUC và confusion matrix cũng giúp đánh giá mô hình một cách toàn diện hơn, đặc biệt trong bối cảnh dữ liệu có sự mất cân bằng giữa các lớp bệnh. Một điểm có ý nghĩa khác của đề tài là việc bổ sung thành phần giải thích kết quả dự đoán thông qua heatmap. Heatmap giúp trực quan hóa vùng ảnh có ảnh hưởng đến quyết định của mô hình, từ đó hỗ trợ người dùng quan sát và đối chiếu kết quả dự đoán. Mặc dù heatmap không thay thế cho phân đoạn tổn thương y khoa, thành phần này vẫn giúp tăng tính minh bạch của hệ thống AI trong quá trình trình bày và phân tích kết quả.

1.5.2. Ý nghĩa thực tiễn

Về mặt thực tiễn, đề tài xây dựng một hệ thống phần mềm có khả năng hỗ trợ phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt. Hệ thống cho phép người dùng upload ảnh, sau đó tự động thực hiện tiền xử lý, chạy mô hình dự đoán và hiển thị kết quả phân loại. Nhờ đó, mô hình học sâu không chỉ dừng lại ở mức thực nghiệm mà còn được triển khai thành một ứng dụng web minh họa có thể sử dụng trực tiếp.

Hệ thống có thể hỗ trợ quá trình sàng lọc ban đầu bằng cách cung cấp thông tin tham khảo về mức độ bệnh dự đoán. Ngoài nhãn phân loại cuối cùng, hệ thống còn hiển thị xác suất dự đoán của từng lớp, kết quả của từng mô hình, kết quả ensemble, ảnh sau tiền xử lý và heatmap giải thích. Những thông tin này giúp người dùng có cái nhìn rõ hơn về kết quả mà mô hình đưa ra, thay vì chỉ nhận một nhãn dự đoán đơn lẻ.

Đề tài cũng có ý nghĩa trong việc hỗ trợ giảm tải cho quy trình đánh giá thủ công trong bối cảnh số lượng ảnh cần sàng lọc có thể lớn. Một hệ thống AI có khả năng xử lý ảnh nhanh và nhất quán có thể được sử dụng như công cụ hỗ trợ tham khảo trước khi người bệnh được thăm khám hoặc đánh giá bởi bác sĩ chuyên khoa. Tuy nhiên, hệ thống không được xây dựng với mục tiêu thay thế bác sĩ mà chỉ đóng vai trò hỗ trợ trong phạm vi nghiên cứu và thử nghiệm.

Ngoài ra, hệ thống được thiết kế có cảnh báo khi mô hình chưa chắc chắn giữa các mức bệnh lân cận, đặc biệt là giữa Moderate DR và Severe DR. Điều này có ý nghĩa thực tiễn vì giúp hạn chế việc người dùng hiểu nhầm kết quả dự đoán là kết luận tuyệt đối. Thay vào đó, hệ thống nhấn mạnh rằng các trường hợp có độ bất định cao hoặc nghi ngờ mức bệnh nặng cần được kiểm tra lại bởi bác sĩ chuyên khoa mắt.

Từ góc độ học tập và phát triển phần mềm, đề tài giúp sinh viên vận dụng kiến thức về xử lý ảnh, học sâu, đánh giá mô hình, xây dựng API và phát triển giao diện web vào một bài toán có tính ứng dụng thực tế. Đây cũng là cơ sở để mở rộng đề tài trong tương lai, chẳng hạn như bổ sung dữ liệu ngoài, cải thiện khả năng phân loại các lớp bệnh nặng, tích hợp phân đoạn tổn thương hoặc phát triển thành hệ thống hỗ trợ quản lý kết quả khám mắt.

1.6. Đóng góp của đề tài

Đề tài “Phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt” tập trung xây dựng một quy trình tương đối hoàn chỉnh từ khâu xử lý dữ liệu ảnh, huấn luyện mô hình học sâu đến triển khai mô hình thành hệ thống web hỗ trợ dự đoán. Trong phạm vi nghiên cứu, đề tài đã xây dựng pipeline tiền xử lý ảnh đáy mắt gồm các bước loại bỏ vùng viền đen, tăng cường tương phản cục bộ bằng CLAHE, thay đổi kích thước ảnh về 320×320 và chuẩn hóa ảnh theo yêu cầu đầu vào của từng mô hình. Quy trình này giúp dữ liệu ảnh đầu vào đồng nhất hơn, hạn chế ảnh hưởng của các vùng không chứa thông tin y khoa và hỗ trợ mô hình tập trung tốt hơn vào vùng võng mạc.

Về mô hình học sâu, đề tài sử dụng hai kiến trúc mạng nơ-ron tích chập là DenseNet121 và EfficientNetB3 để phân loại 5 mức độ bệnh võng mạc đái tháo đường từ ảnh đáy mắt. Hai mô hình này được huấn luyện và đánh giá riêng lẻ nhằm phân tích khả năng dự đoán của từng kiến trúc. Sau đó, đề tài áp dụng phương pháp ensemble weighted average để kết hợp xác suất đầu ra của hai mô hình, trong đó kết quả dự đoán cuối cùng được xác định dựa trên lớp có xác suất cao nhất sau khi kết hợp. Việc sử dụng ensemble giúp tận dụng ưu điểm của từng mô hình CNN và cải thiện độ ổn định của kết quả phân loại so với việc chỉ sử dụng một mô hình đơn lẻ.

Một đóng góp quan trọng khác của đề tài là quá trình đánh giá mô hình được thực hiện bằng nhiều chỉ số khác nhau thay vì chỉ dựa vào accuracy. Các chỉ số như precision, recall, F1-score, macro-F1, weighted-F1, Quadratic Weighted Kappa, AUC và confusion matrix được sử dụng để đánh giá kết quả ở cả mức tổng thể và từng lớp bệnh. Cách đánh giá này giúp nhận diện rõ hơn những lớp mô hình dự đoán tốt và những lớp còn hạn chế. Đặc biệt, đề tài có phân tích riêng lớp Severe DR do lớp này dễ bị nhầm lẫn với Moderate DR. Từ kết quả phân tích, hệ thống được bổ sung cơ chế cảnh báo khi mô hình chưa chắc chắn giữa các mức bệnh lân cận, giúp người dùng hiểu rằng kết quả dự đoán chỉ mang tính hỗ trợ tham khảo và cần được kiểm tra lại bởi bác sĩ chuyên khoa trong các trường hợp nghi ngờ.

Bên cạnh phần mô hình, đề tài còn tích hợp thành phần trực quan hóa kết quả bằng heatmap nhằm thể hiện vùng ảnh có ảnh hưởng đến quyết định của mô hình. Heatmap giúp người dùng quan sát trực quan hơn quá trình mô hình tập trung vào các vùng trên ảnh đáy mắt khi đưa ra dự đoán, tuy nhiên không được xem là kết quả phân

đoạn tổn thương y khoa. Cuối cùng, đề tài đã triển khai mô hình thành một ứng dụng web minh họa cho phép người dùng upload ảnh đáy mắt, xem ảnh gốc, ảnh sau tiền xử lý, nhãn dự đoán, xác suất từng lớp, kết quả từng mô hình, kết quả ensemble, heatmap, cảnh báo y tế và báo cáo kết quả. Nhìn chung, đóng góp của đề tài không nằm ở việc đề xuất một kiến trúc học sâu hoàn toàn mới, mà tập trung vào việc lựa chọn, huấn luyện, kết hợp và triển khai các mô hình CNN phù hợp cho bài toán phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt trong phạm vi nghiên cứu học thuật.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

2.1. Tổng quan về bệnh võng mạc đái tháo đường

Bệnh võng mạc đái tháo đường là một biến chứng thường gặp của bệnh đái tháo đường, xảy ra khi tình trạng rối loạn chuyển hóa đường huyết kéo dài gây ảnh hưởng đến hệ thống vi mạch tại võng mạc. Võng mạc là lớp mô thần kinh nằm ở phía sau nhãn cầu, có vai trò tiếp nhận ánh sáng và truyền tín hiệu thị giác về não. Khi các mạch máu nhỏ tại võng mạc bị tổn thương, người bệnh có thể xuất hiện các bất thường như vi phình mạch, xuất huyết, xuất tiết, phù hoàng điểm hoặc tăng sinh mạch máu bất thường. Những tổn thương này nếu tiến triển nặng có thể làm suy giảm thị lực và ảnh hưởng đến chất lượng cuộc sống của người bệnh [6], [7].

Về mặt lâm sàng, bệnh võng mạc đái tháo đường thường được phân thành nhiều mức độ khác nhau dựa trên các dấu hiệu quan sát được ở võng mạc. Một hệ thống phân loại được sử dụng phổ biến chia bệnh thành các mức độ từ không có bệnh, bệnh mức độ nhẹ, trung bình, nặng cho đến bệnh võng mạc đái tháo đường tăng sinh [5]. Trong bài toán phân loại ảnh đáy mắt, cách chia này thường được biểu diễn thành 5 lớp: No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Đây cũng là cách gán nhãn được sử dụng trong tập dữ liệu APTOS 2019 Blindness Detection, phù hợp với mục tiêu của đề tài là xây dựng mô hình phân loại 5 mức độ bệnh từ ảnh đáy mắt [9].

Ở các giai đoạn đầu, bệnh có thể chưa gây ra triệu chứng rõ ràng cho người bệnh, trong khi các dấu hiệu bất thường đã có thể xuất hiện trên ảnh đáy mắt. Điều này làm cho việc sàng lọc định kỳ trở nên quan trọng, đặc biệt đối với người mắc bệnh đái tháo đường trong thời gian dài hoặc kiểm soát đường huyết chưa tốt. Ảnh đáy mắt cho phép quan sát trực tiếp các cấu trúc quan trọng như gai thị, hệ thống mạch máu võng mạc và vùng hoàng điểm, từ đó hỗ trợ phát hiện các dấu hiệu bất thường liên quan đến bệnh võng mạc đái tháo đường. Tuy nhiên, việc đánh giá ảnh đáy mắt theo phương pháp thủ công phụ thuộc nhiều vào kinh nghiệm của người đọc ảnh, chất lượng ảnh và điều kiện chuyên môn tại cơ sở y tế.

Trong bối cảnh đó, các phương pháp xử lý ảnh và học sâu được nghiên cứu nhằm hỗ trợ phân tích ảnh đáy mắt một cách tự động. Đối với đề tài này, bệnh võng mạc đái tháo đường được xem xét dưới góc độ bài toán phân loại ảnh y tế, trong đó mỗi ảnh đáy mắt đầu vào được mô hình dự đoán thuộc một trong 5 mức độ bệnh. Việc hiểu rõ đặc điểm bệnh, các mức độ phân loại và vai trò của ảnh đáy mắt là cơ sở quan trọng để lựa chọn dữ liệu, xây dựng pipeline tiền xử lý, huấn luyện mô hình CNN và đánh giá kết quả dự đoán trong các chương tiếp theo.

2.2. Tổng quan về học sâu trong xử lý ảnh y tế

Học sâu là một nhánh của học máy, trong đó mô hình sử dụng nhiều lớp xử lý liên tiếp để tự động học đặc trưng từ dữ liệu. Khác với các phương pháp học máy truyền thống thường cần thiết kế đặc trưng thủ công, mô hình học sâu có khả năng tự học các đặc trưng ở nhiều mức độ khác nhau, từ các đặc trưng đơn giản như cạnh, vùng sáng tối, kết cấu cho đến các đặc trưng phức tạp hơn liên quan đến hình dạng và cấu trúc của đối tượng trong ảnh. Nhờ khả năng này, học sâu đã được ứng dụng rộng rãi trong các bài toán xử lý ảnh, đặc biệt là phân loại, phát hiện và phân đoạn ảnh y tế [13]. Trong lĩnh vực ảnh y tế, dữ liệu thường có đặc điểm phức tạp, sự khác biệt giữa vùng bình thường và vùng bất thường đôi khi không rõ ràng, đồng thời các mức độ bệnh có thể chỉ khác nhau ở những chi tiết nhỏ. Vì vậy, việc sử dụng các mô hình có khả năng tự động trích xuất đặc trưng từ ảnh là cần thiết.

Một trong những kiến trúc học sâu được sử dụng phổ biến cho dữ liệu ảnh là mạng nơ-ron tích chập, hay Convolutional Neural Network. CNN hoạt động thông qua các lớp tích chập để học đặc trưng không gian trong ảnh, các lớp giảm kích thước biểu diễn và các lớp phân loại để đưa ra kết quả dự đoán. Trong bài toán phân loại bệnh võng mạc đáy tháo đường, ảnh đáy mắt sau khi được tiền xử lý sẽ được đưa vào mô hình CNN để trích xuất đặc trưng, sau đó mô hình dự đoán xác suất ảnh thuộc về từng mức độ bệnh. Cách tiếp cận này phù hợp với mục tiêu của đề tài vì dữ liệu đầu vào là ảnh đáy mắt và đầu ra là một trong 5 lớp bệnh, gồm No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR.

Tuy nhiên, việc áp dụng học sâu trong ảnh y tế cũng cần được thực hiện thận trọng. Dữ liệu y tế thường có sự mất cân bằng giữa các lớp, chất lượng ảnh đầu vào không đồng nhất và kết quả dự đoán sai có thể gây hiểu nhầm về tình trạng bệnh. Do đó, đề tài không chỉ tập trung vào việc huấn luyện mô hình CNN mà còn kết hợp các bước tiền xử lý ảnh, xử lý mất cân bằng dữ liệu, đánh giá bằng nhiều chỉ số và bổ sung cảnh báo khi mô hình chưa chắc chắn. Trong phạm vi đề tài này, hai kiến trúc CNN được sử dụng là DenseNet121 và EfficientNetB3. DenseNet121 có ưu điểm trong việc truyền và tái sử dụng đặc trưng giữa các lớp, trong khi EfficientNetB3 được thiết kế theo hướng cân bằng giữa độ sâu, độ rộng và độ phân giải của mạng [19], [20]. Việc sử dụng hai mô hình CNN khác nhau giúp đề tài có cơ sở để so sánh hiệu quả từng mô hình và kết hợp kết quả dự đoán bằng phương pháp ensemble ở các bước sau.

2.3. Các mô hình học sâu sử dụng trong đề tài

Trong đề tài này, hai mô hình học sâu được sử dụng để phân loại bệnh võng mạc đáy tháo đường từ ảnh đáy mắt là DenseNet121 và EfficientNetB3. Cả hai đều thuộc nhóm mạng nơ-ron tích chập CNN, phù hợp với dữ liệu ảnh và có khả năng tự động

trích xuất đặc trưng từ ảnh đầu vào. Việc lựa chọn hai mô hình này xuất phát từ mục tiêu khai thác đặc trưng ảnh đáy mắt theo hai kiến trúc khác nhau, sau đó kết hợp kết quả dự đoán để tạo ra mô hình phân loại ổn định hơn. Trong bài toán ảnh y tế nói chung và ảnh đáy mắt nói riêng, các đặc trưng bất thường có thể xuất hiện ở nhiều kích thước và vị trí khác nhau, do đó việc sử dụng các mô hình CNN có khả năng học đặc trưng sâu là cần thiết.

DenseNet121 là một kiến trúc CNN được xây dựng dựa trên ý tưởng kết nối dày đặc giữa các lớp trong mạng. Thay vì mỗi lớp chỉ nhận đầu vào từ lớp ngay trước nó, DenseNet cho phép một lớp nhận thông tin đặc trưng từ nhiều lớp trước đó. Cách thiết kế này giúp mô hình tái sử dụng đặc trưng tốt hơn, hỗ trợ quá trình lan truyền gradient và giảm tình trạng mất mát thông tin khi mạng trở nên sâu hơn [19]. Đối với bài toán phân loại ảnh đáy mắt, DenseNet121 có thể hỗ trợ học các đặc trưng liên quan đến cấu trúc võng mạc, mạch máu và các vùng bất thường trên ảnh. Vì vậy, mô hình này được lựa chọn như một trong hai backbone chính của đề tài.

EfficientNetB3 là một mô hình thuộc họ EfficientNet, được thiết kế dựa trên nguyên lý mở rộng mô hình một cách cân bằng giữa độ sâu, độ rộng và độ phân giải ảnh đầu vào. Thay vì chỉ tăng số lớp hoặc số kênh một cách riêng lẻ, EfficientNet sử dụng phương pháp compound scaling để mở rộng mạng theo nhiều chiều một cách hợp lý, từ đó giúp cải thiện hiệu quả học đặc trưng trong khi vẫn kiểm soát được số lượng tham số và chi phí tính toán [20]. Trong phạm vi đề tài, EfficientNetB3 được lựa chọn vì có khả năng biểu diễn tốt hơn so với các phiên bản nhỏ hơn, đồng thời vẫn phù hợp với điều kiện huấn luyện trên môi trường Kaggle. Mô hình này đóng vai trò quan trọng trong việc trích xuất đặc trưng ảnh và đưa ra xác suất dự đoán cho từng mức độ bệnh.

Việc sử dụng đồng thời DenseNet121 và EfficientNetB3 giúp đề tài có cơ sở để so sánh hiệu quả giữa hai kiến trúc CNN khác nhau. Sau khi huấn luyện riêng từng mô hình, xác suất dự đoán của hai mô hình được kết hợp bằng phương pháp ensemble weighted average. Trong đó, EfficientNetB3 được gán trọng số 0,55 và DenseNet121 được gán trọng số 0,45. Cách kết hợp này nhằm tận dụng ưu điểm của từng mô hình, giảm sự phụ thuộc vào một mô hình đơn lẻ và cải thiện độ ổn định của kết quả phân loại. Như vậy, DenseNet121 và EfficientNetB3 không chỉ được sử dụng như hai mô hình độc lập mà còn là hai thành phần chính trong mô hình ensemble cuối cùng của hệ thống.

2.4. Phương pháp ensemble learning

Ensemble learning là phương pháp kết hợp nhiều mô hình học máy hoặc học sâu nhằm tạo ra một kết quả dự đoán cuối cùng ổn định hơn so với việc chỉ sử dụng một mô hình đơn lẻ. Trong các bài toán phân loại ảnh, mỗi mô hình có thể học được những đặc trưng khác nhau từ dữ liệu, do đó kết quả dự đoán của từng mô hình cũng có thể khác nhau ở một số trường hợp. Việc kết hợp nhiều mô hình giúp tận dụng ưu điểm của từng mô hình riêng lẻ, đồng thời giảm sự phụ thuộc vào sai số của một mô hình duy nhất. Trong lĩnh vực phân loại bệnh võng mạc đái tháo đường, một số nghiên cứu gần đây cũng sử dụng hướng tiếp cận ensemble để cải thiện hiệu quả phân loại trên ảnh đáy mắt [45], [47], [48].

Trong đề tài này, phương pháp ensemble được sử dụng để kết hợp kết quả dự đoán của hai mô hình CNN là DenseNet121 và EfficientNetB3. Sau khi ảnh đáy mắt được tiền xử lý, ảnh sẽ lần lượt được đưa vào hai mô hình để tạo ra hai vector xác suất tương ứng với 5 mức độ bệnh. Mỗi vector xác suất thể hiện mức độ tin cậy của mô hình đối với từng lớp, bao gồm No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Thay vì chọn trực tiếp kết quả từ một mô hình, đề tài kết hợp hai vector xác suất này bằng phương pháp trung bình có trọng số, hay weighted average ensemble.

Công thức kết hợp được sử dụng trong đề tài như sau:

$$P_final = 0,55 \times P_EfficientNetB3 + 0,45 \times P_DenseNet121$$

Trong đó, $P_EfficientNetB3$ là vector xác suất đầu ra của mô hình EfficientNetB3, $P_DenseNet121$ là vector xác suất đầu ra của mô hình DenseNet121, còn P_final là vector xác suất sau khi kết hợp. Sau khi tính được P_final , lớp có xác suất lớn nhất sẽ được chọn làm kết quả dự đoán cuối cùng. Việc gán trọng số 0,55 cho EfficientNetB3 và 0,45 cho DenseNet121 được thực hiện dựa trên kết quả thực nghiệm, trong đó EfficientNetB3 có hiệu quả tổng thể nhìn hơn nhưng DenseNet121 vẫn đóng góp vào việc ổn định kết quả phân loại.

Việc sử dụng ensemble trong đề tài có ý nghĩa quan trọng vì bài toán phân loại bệnh võng mạc đáy tháo đường có sự khác biệt không đồng đều giữa các lớp. Một số lớp bệnh có biểu hiện rõ ràng hơn, trong khi một số lớp lân cận như Moderate DR và Severe DR có thể dễ bị nhầm lẫn do đặc điểm ảnh tương đối gần nhau. Khi kết hợp hai mô hình CNN có kiến trúc khác nhau, hệ thống có thêm cơ sở để đưa ra kết quả dự đoán cân bằng hơn. Tuy nhiên, ensemble không loại bỏ hoàn toàn sai số của mô hình, vì vậy đề tài vẫn bổ sung cơ chế cảnh báo khi xác suất giữa các lớp bệnh lân cận gần nhau, nhằm nhấn mạnh rằng kết quả của hệ thống chỉ có vai trò hỗ trợ tham khảo.

2.5. Tiền xử lý ảnh đáy mắt

Tiền xử lý ảnh là bước quan trọng trước khi đưa ảnh đáy mắt vào mô hình học sâu. Ảnh đáy mắt thu được từ các thiết bị chụp khác nhau có thể tồn tại sự khác biệt về kích thước, độ sáng, độ tương phản, vùng viền đen xung quanh võng mạc hoặc chất lượng ảnh. Nếu đưa trực tiếp ảnh gốc vào mô hình, các yếu tố không liên quan đến bệnh như nền đen, ánh sáng không đồng đều hoặc kích thước ảnh khác nhau có thể ảnh hưởng đến quá trình học đặc trưng. Vì vậy, trong đề tài này, ảnh đầu vào được xử lý theo một pipeline thống nhất trước khi đưa vào hai mô hình DenseNet121 và EfficientNetB3.

Quy trình tiền xử lý được sử dụng trong đề tài gồm các bước chính: loại bỏ vùng viền đen, tăng cường tương phản cục bộ bằng CLAHE, thay đổi kích thước ảnh về 320×320 và chuẩn hóa ảnh theo yêu cầu đầu vào của từng mô hình. Bước loại bỏ vùng viền đen giúp giảm bớt các vùng không chứa thông tin y khoa, từ đó tập trung vùng ảnh vào phần võng mạc. Sau đó, CLAHE được áp dụng nhằm cải thiện độ tương phản cục bộ của ảnh, giúp làm rõ hơn hệ thống mạch máu và một số vùng bất thường trên võng mạc. CLAHE là một biến thể của phương pháp cân bằng histogram thích nghi, có cơ chế giới hạn độ khuếch đại tương phản để tránh làm nhiễu ảnh quá mức [23], [24]. Sau khi tăng cường tương phản, ảnh được resize về kích thước 320×320 để phù hợp với cấu hình đầu vào của mô hình trong quá trình huấn luyện và suy luận.

Trong phạm vi đề tài, quy trình tiền xử lý được lựa chọn theo hướng đơn giản, nhất quán và hạn chế làm thay đổi bản chất thông tin y khoa trong ảnh. Một số kỹ thuật nâng cao như siêu phân giải ảnh bằng ESRGAN không được sử dụng trong phiên bản cuối cùng, mặc dù các kỹ thuật này có thể làm ảnh nhìn sắc nét hơn về mặt trực quan. Lý do là trong bài toán ảnh y tế, việc tạo thêm hoặc làm biến đổi chi tiết ảnh cần được kiểm chứng thận trọng, vì các chi tiết được sinh thêm có thể gây hiểu nhầm khi phân tích tổn thương. Do đó, đề tài ưu tiên pipeline an toàn hơn gồm crop viền đen, CLAHE, resize và chuẩn hóa ảnh. Cách tiếp cận này phù hợp với mục tiêu xây dựng hệ thống hỗ trợ phân loại, trong đó ảnh sau tiền xử lý được sử dụng làm đầu vào cho mô hình và đồng thời được hiển thị trên giao diện web để người dùng có thể đối chiếu với ảnh gốc.

2.6. Các chỉ số đánh giá mô hình

Trong bài toán phân loại bệnh võng mạc đáy mắt, việc đánh giá mô hình không nên chỉ dựa vào một chỉ số duy nhất. Nguyên nhân là dữ liệu ảnh y tế thường có sự mất cân bằng giữa các lớp, trong đó lớp không bệnh hoặc bệnh nhẹ có thể chiếm số lượng lớn hơn so với các lớp bệnh nặng. Nếu chỉ sử dụng accuracy, mô hình có thể đạt độ chính xác tổng thể tương đối cao nhưng vẫn dự đoán kém ở các lớp ít mẫu. Vì vậy, đề tài sử dụng nhiều chỉ số đánh giá khác nhau nhằm phản ánh hiệu quả mô hình ở cả mức tổng thể và từng lớp bệnh.

Accuracy cho biết tỷ lệ mẫu được dự đoán đúng trên tổng số mẫu kiểm tra. Đây là chỉ số dễ hiểu và thường được sử dụng trong các bài toán phân loại. Tuy nhiên, trong bối cảnh dữ liệu mất cân bằng, accuracy chưa đủ để đánh giá toàn diện hiệu quả của mô hình. Do đó, đề tài sử dụng thêm precision, recall và F1-score. Precision thể hiện trong số các mẫu được mô hình dự đoán thuộc một lớp thì có bao nhiêu mẫu thực sự thuộc lớp đó. Recall thể hiện trong số các mẫu thực sự thuộc một lớp thì mô hình nhận diện đúng được bao nhiêu mẫu. F1-score là trung bình điều hòa giữa precision và recall, giúp đánh giá cân bằng hơn giữa khả năng dự đoán đúng và khả năng phát hiện đủ mẫu của từng lớp [30], [31].

Bên cạnh F1-score theo từng lớp, đề tài còn sử dụng macro-F1 và weighted-F1 để đánh giá kết quả trên toàn bộ các lớp. Macro-F1 tính trung bình F1-score của các lớp với trọng số như nhau, do đó phản ánh tốt hơn hiệu quả của mô hình đối với các lớp ít mẫu. Weighted-F1 cũng tính trung bình F1-score của các lớp nhưng có xét đến số lượng mẫu của từng lớp, vì vậy chỉ số này thường chịu ảnh hưởng nhiều hơn từ các lớp có số lượng ảnh lớn. Trong bài toán phân loại 5 mức độ bệnh võng mạc đáy mắt, macro-F1 là chỉ số quan trọng vì giúp đánh giá mô hình có học tốt các

lớp bệnh ít mẫu hay không, đặc biệt là các lớp bệnh nặng như Severe DR và Proliferative DR.

Ngoài các chỉ số trên, đề tài sử dụng confusion matrix để phân tích chi tiết mô hình dự đoán đúng và sai ở từng lớp. Ma trận nhầm lẫn cho phép quan sát mô hình thường nhầm lớp nào với lớp nào, từ đó nhận diện các lỗi quan trọng trong quá trình phân loại. Đối với đề tài này, confusion matrix có ý nghĩa đặc biệt trong việc phân tích sự nhầm lẫn giữa Moderate DR và Severe DR. Bên cạnh đó, Quadratic Weighted Kappa được sử dụng vì bài toán phân loại bệnh võng mạc đái tháo đường có tính thứ bậc, nghĩa là sai lệch giữa lớp 2 và lớp 3 ít nghiêm trọng hơn sai lệch giữa lớp 0 và lớp 4. QWK giúp đánh giá mức độ đồng thuận giữa nhãn dự đoán và nhãn thực tế, đồng thời phạt nặng hơn các dự đoán sai lệch xa về mức độ bệnh [28]. AUC cũng được sử dụng để đánh giá khả năng phân biệt giữa các lớp của mô hình, đặc biệt trong trường hợp phân loại đa lớp theo hướng one-vs-rest [29]. Việc kết hợp nhiều chỉ số đánh giá giúp đề tài nhận xét mô hình một cách thận trọng hơn, phù hợp với đặc thù của bài toán ảnh y tế.

2.7. Giải thích mô hình AI trong ảnh y tế

Trong các bài toán ứng dụng trí tuệ nhân tạo vào y tế, kết quả dự đoán của mô hình không chỉ cần đạt độ chính xác cao mà còn cần có khả năng giải thích ở một mức độ nhất định. Đối với mô hình học sâu, đặc biệt là các mạng CNN có nhiều lớp xử lý, quá trình mô hình đưa ra quyết định thường khó quan sát trực tiếp. Người dùng chỉ nhìn thấy kết quả cuối cùng như nhãn dự đoán hoặc xác suất dự đoán, trong khi không biết mô hình đã tập trung vào vùng nào trên ảnh để đưa ra kết luận. Điều này tạo ra nhu cầu sử dụng các phương pháp giải thích mô hình nhằm tăng tính minh bạch, đặc biệt trong các hệ thống hỗ trợ phân tích ảnh y tế, nơi kết quả dự đoán cần được diễn giải thận trọng và không nên được xem như kết luận tuyệt đối [34], [35].

Một hướng giải thích phổ biến trong xử lý ảnh là tạo heatmap để trực quan hóa các vùng ảnh có ảnh hưởng nhiều hơn đến quyết định của mô hình. Heatmap thường được biểu diễn dưới dạng một bản đồ màu hoặc bản đồ cường độ chồng lên ảnh gốc, trong đó các vùng nổi bật thể hiện khu vực mô hình quan tâm nhiều hơn khi đưa ra dự đoán. Các phương pháp như Grad-CAM và Integrated Gradients thường được sử dụng để hỗ trợ giải thích mô hình học sâu thông qua việc phân tích gradient hoặc mức đóng góp của các vùng ảnh đối với kết quả đầu ra [32], [33]. Trong bài toán phân loại bệnh võng mạc đái tháo đường, heatmap có thể giúp người dùng quan sát mô hình đang tập trung vào vùng nào trên ảnh đáy mắt, chẳng hạn vùng gần hoàng điểm, mạch máu hoặc các vùng có đặc điểm bất thường.

Trong phạm vi đề tài này, heatmap được sử dụng như một thành phần hỗ trợ giải thích kết quả dự đoán của hệ thống. Sau khi ảnh đáy mắt được tiền xử lý và đưa qua các

mô hình DenseNet121, EfficientNetB3, hệ thống sinh heatmap để biểu diễn vùng ảnh có ảnh hưởng đến quyết định phân loại. Trên giao diện web, heatmap được hiển thị cùng với ảnh gốc và ảnh sau tiền xử lý, giúp người dùng đối chiếu giữa dữ liệu đầu vào, dữ liệu mô hình sử dụng và vùng ảnh mà mô hình chú ý. Việc hiển thị đồng thời ba ảnh này giúp kết quả dự đoán trở nên dễ quan sát hơn, thay vì chỉ trình bày một nhãn phân loại cuối cùng. Tuy nhiên, cần nhấn mạnh rằng heatmap trong đề tài chỉ có vai trò hỗ trợ trực quan và giải thích ở mức tham khảo. Heatmap không phải là kết quả phân đoạn tổn thương võng mạc, không xác định chính xác loại tổn thương như vi phình mạch, xuất huyết hay xuất tiết, và cũng không thay thế cho đánh giá của bác sĩ chuyên khoa. Một vùng sáng trên heatmap chỉ cho thấy khu vực đó có ảnh hưởng đến quyết định của mô hình, chứ không khẳng định chắc chắn đó là vùng tổn thương y khoa. Vì vậy, khi triển khai trên hệ thống web, kết quả heatmap luôn được trình bày kèm cảnh báo rằng hệ thống chỉ hỗ trợ tham khảo và không thay thế chẩn đoán y tế.

2.8. Các nghiên cứu liên quan trong 5 năm gần đây

Trong những năm gần đây, bài toán phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt tiếp tục nhận được nhiều sự quan tâm, đặc biệt với sự phát triển của các mô hình học sâu dựa trên mạng nơ-ron tích chập. Các nghiên cứu thường tập trung vào việc lựa chọn kiến trúc CNN phù hợp, xử lý mất cân bằng dữ liệu, cải thiện chất lượng ảnh đầu vào và đánh giá mô hình trên các tập dữ liệu công khai như APTOS 2019, EyePACS hoặc DDR. Tuy nhiên, kết quả giữa các nghiên cứu có sự khác biệt đáng kể do phụ thuộc vào số lớp phân loại, cách chia dữ liệu, tiền xử lý ảnh, chiến lược tăng cường dữ liệu và chỉ số đánh giá. Vì vậy, khi so sánh với đề tài này, các công trình liên quan được lựa chọn chủ yếu là những nghiên cứu có bài toán gần với phân loại đa lớp bệnh võng mạc đái tháo đường, đặc biệt là các nghiên cứu có kết quả thấp hơn hoặc xấp xỉ mô hình ensemble v3 của đề tài.

Hannan và cộng sự đề xuất một mô hình học sâu có tích hợp cơ chế dual-attention nhằm cải thiện khả năng phân loại bệnh võng mạc đái tháo đường trong bối cảnh dữ liệu mất cân bằng. Nghiên cứu sử dụng ba backbone tiền huấn luyện gồm MobileNetV3-small, EfficientNet-b0 và DenseNet-169, sau đó kết hợp các khối attention để giúp mô hình tập trung tốt hơn vào các đặc trưng quan trọng. Mô hình được đánh giá trên hai tập dữ liệu APTOS và EyePACS. Trên tập APTOS, DenseNet-169 đạt accuracy trung bình 83,20%, MobileNetV3-small đạt 82% và EfficientNet-b0 đạt 80%; ngoài ra nghiên cứu còn báo cáo F1-score khoảng 82,0% và kappa score khoảng 88,2% [51]. Ưu điểm của nghiên cứu là quan tâm trực tiếp đến vấn đề mất cân bằng dữ liệu và thử nghiệm trên nhiều backbone khác nhau. Tuy nhiên, kết quả accuracy và kappa vẫn thấp hơn kết quả ensemble v3 của đề tài, trong đó đề tài đạt accuracy 84,73% và QWK 0,9042. Điều này cho thấy hướng kết hợp DenseNet121

và EfficientNetB3 bằng weighted average ensemble trong đề tài có tính cạnh tranh so với một số mô hình attention gần đây.

Một nghiên cứu khác có liên quan là công trình “Deep Learning Empowered Diagnosis of Diabetic Retinopathy”, trong đó các tác giả sử dụng hai mô hình tiền huấn luyện ResNet50 và DenseNet-121 để phân loại bệnh võng mạc đái tháo đường trên tập dữ liệu APTOS. Nghiên cứu đánh giá cả bài toán nhị phân và bài toán đa lớp. Đối với phân loại đa lớp, DenseNet-121 đạt accuracy 82,0% và ResNet50 đạt accuracy 80,8% [52]. Ưu điểm của nghiên cứu là sử dụng các backbone CNN phổ biến và có so sánh giữa hai kiến trúc khác nhau trên cùng dữ liệu. Tuy nhiên, nghiên cứu không tập trung nhiều vào tiền xử lý ảnh chuyên biệt, cơ chế ensemble hoặc giải thích kết quả dự đoán. So với nghiên cứu này, đề tài không chỉ sử dụng DenseNet121 mà còn kết hợp thêm EfficientNetB3, áp dụng tiền xử lý ảnh bằng crop viền đen, CLAHE, resize và kết hợp xác suất đầu ra bằng ensemble weighted average. Nhờ đó, kết quả accuracy của đề tài cao hơn kết quả từng mô hình đơn trong nghiên cứu trên.

Ahmed tập trung vào vấn đề mất cân bằng dữ liệu trong phân loại bệnh võng mạc đái tháo đường, đặc biệt ở bài toán 5 lớp trên tập APTOS 2019. Nghiên cứu sử dụng transfer learning với nhiều kiến trúc CNN tiền huấn luyện, kết hợp chiến lược tăng cường dữ liệu nhằm cân bằng số lượng ảnh giữa các lớp. Đối với bài toán nhị phân, nghiên cứu đạt kết quả rất cao; tuy nhiên, ở bài toán phân loại 5 mức độ bệnh, mô hình đạt accuracy 84,6% và AUC 94,1% [53]. Ưu điểm của nghiên cứu là tập trung trực tiếp vào bài toán mất cân bằng lớp và có đánh giá riêng cho phân loại 5 lớp, phù hợp với hướng nghiên cứu của đề tài. Nhược điểm là kết quả ở bài toán 5 lớp vẫn còn thấp hơn nhẹ so với đề tài, trong đó mô hình ensemble v3 đạt accuracy 84,73% và AUC 0,9522. Khi so sánh với công trình này, đề tài có thể được xem là đạt kết quả tương đương hoặc nhỉnh hơn nhẹ ở bài toán 5 lớp, đồng thời bổ sung thêm hệ thống web, heatmap giải thích và cảnh báo khi mô hình chưa chắc chắn giữa các mức bệnh lân cận.

Youldash và cộng sự nghiên cứu hướng phát hiện và phân loại sớm bệnh võng mạc đái tháo đường bằng mô hình học sâu trên ảnh đáy mắt. Nghiên cứu sử dụng mô hình CNN512 cho nhiệm vụ phân loại và YOLOv3 cho nhiệm vụ định vị tổn thương. Kết quả cho thấy CNN512 đạt accuracy 88,6% trên tập DDR và 84,1% trên tập APTOS; đối với định vị tổn thương, YOLOv3 đạt mAP 0,216 trên DDR [54]. Ưu điểm của nghiên cứu là kết hợp cả phân loại và định vị tổn thương, cho thấy hướng phát triển rộng hơn so với chỉ phân loại ảnh. Tuy nhiên, accuracy trên APTOS của mô hình phân loại vẫn thấp hơn kết quả ensemble của đề tài. Ngoài ra, độ chính xác định vị tổn thương còn hạn chế, cho thấy bài toán định vị hoặc phân đoạn tổn thương võng mạc vẫn là một vấn đề khó. So với nghiên cứu này, đề tài tập trung sâu hơn vào bài toán phân loại 5 mức độ DR, sử dụng ensemble hai mô hình CNN và bổ sung

heatmap để hỗ trợ giải thích trực quan, nhưng không khẳng định heatmap là kết quả phân đoạn tổn thương.

Minarno và cộng sự sử dụng mô hình InceptionV3 cho bài toán phân loại bệnh võng mạc đáy tháo đường từ ảnh fundus. Nghiên cứu áp dụng tăng cường dữ liệu nhằm hạn chế hiện tượng overfitting và cải thiện khả năng tổng quát hóa của mô hình. Kết quả cho thấy mô hình đạt accuracy 86,5% trên tập huấn luyện và 82,73% trên tập kiểm tra [55]. Ưu điểm của nghiên cứu là sử dụng một kiến trúc CNN phổ biến và chỉ ra vai trò của data augmentation trong việc giảm overfitting. Tuy nhiên, khoảng cách giữa accuracy huấn luyện và accuracy kiểm tra cho thấy mô hình vẫn còn chịu ảnh hưởng của khả năng tổng quát hóa. So với nghiên cứu này, đề tài đạt accuracy kiểm tra cao hơn, đồng thời sử dụng hai backbone CNN khác nhau thay vì một mô hình đơn. Việc kết hợp DenseNet121 và EfficientNetB3 giúp đề tài giảm sự phụ thuộc vào một kiến trúc duy nhất và tăng độ ổn định của kết quả dự đoán.

Từ các nghiên cứu trên có thể thấy, kết quả của mô hình ensemble v3 trong đề tài có tính cạnh tranh so với một số nghiên cứu gần đây trên bài toán phân loại bệnh võng mạc đáy tháo đường từ ảnh đáy mắt. Đề tài không chỉ đạt accuracy 84,73%, QWK 0,9042, macro-F1 0,7066 và AUC 0,9522, mà còn tích hợp thêm các thành phần phục vụ triển khai thực tế như tiền xử lý ảnh, cảnh báo y tế, heatmap giải thích và giao diện web. Tuy nhiên, cần lưu ý rằng việc so sánh giữa các nghiên cứu chỉ mang tính tham khảo vì mỗi công trình có thể sử dụng cách chia dữ liệu, số lớp phân loại, phương pháp tiền xử lý và môi trường thực nghiệm khác nhau. Do đó, điểm đóng góp chính của đề tài không chỉ nằm ở việc đạt chỉ số tốt hơn một số nghiên cứu, mà còn ở việc xây dựng được một quy trình tương đối hoàn chỉnh từ huấn luyện mô hình đến triển khai hệ thống hỗ trợ dự đoán.

Bảng 2. 1. Các nghiên cứu liên quan

STT	Nghiên cứu	Nội dung	Kết quả	Ưu điểm	Nhược điểm
1	Hannan và cộng sự, 2025 [51]	Đề xuất mô hình dual-attention kết hợp với các backbone MobileNetV3-small, EfficientNet-b0 và DenseNet-169 để phân loại	Trên APTOS: DenseNet-169 đạt 83,20%, MobileNetV3-small đạt 82%, EfficientNet-b0 đạt 80%; F1-score khoảng 82,0%, kappa	Có quan tâm đến mất cân bằng dữ liệu và thử nghiệm nhiều backbone	Đề tài đạt accuracy 84,73% và QWK 0,9042

		DR trên APTOS và EyePACS	khoảng 88,2%		
2	Deep Learning Empowered Diagnosis of Diabetic Retinopathy, 2025 [52]	Sử dụng ResNet50 và DenseNet-121 tiên huấn luyện để phân loại DR trên APTOS, đánh giá cả nhị phân và đa lớp	Phân loại đa lớp: DenseNet-121 đạt 82,0%, ResNet50 đạt 80,8%	Có so sánh hai backbone CNN phổ biến	Chưa kết hợp ensemble và chưa nhận mạnh giải thích kết quả; đề tài cải thiện bằng DenseNet121 + EfficientNetB3 ensemble
3	Ahmed, 2025 [53]	Sử dụng transfer learning và tăng cường dữ liệu để xử lý mất cân bằng trong phân loại nhị phân và 5 lớp DR trên APTOS 2019	Phân loại 5 lớp: accuracy 84,6%, AUC 94,1%	Tập trung trực tiếp vào bài toán mất cân bằng và phân loại 5 lớp	Đề tài đạt accuracy 84,73% và AUC 0,9522
4	Youldash và cộng sự, 2024 [54]	Kết hợp CNN512 cho phân loại và YOLOv3 cho định vị tổn thương trên ảnh đáy mắt	CNN512 đạt 88,6% trên DDR và 84,1% trên APTOS; YOLOv3 đạt mAP 0,216 trên DDR	Có kết hợp phân loại và định vị tổn thương	Đề tài tập trung vào phân loại 5 lớp và heatmap giải thích thay vì định vị tổn thương
5	Minarno và cộng sự, 2025 [55]	Sử dụng InceptionV3 kết hợp tăng cường dữ liệu	Accuracy 86,5% trên tập huấn luyện và 82,73% trên	Cho thấy vai trò của data augmentation trong giảm	Đề tài sử dụng ensemble hai backbone CNN để tăng

		để phân loại DR từ ảnh fundus	tập kiểm tra	overfitting	độ ổn định
--	--	-------------------------------------	--------------	-------------	------------

2.9. Định hướng phương pháp của đề tài

Từ cơ sở lý thuyết và các nghiên cứu liên quan đã trình bày, có thể thấy bài toán phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt thường được tiếp cận theo hướng sử dụng các mô hình học sâu dựa trên mạng nơ-ron tích chập. Các nghiên cứu gần đây cho thấy CNN có khả năng tự động học đặc trưng từ ảnh fundus, trong khi các bước tiền xử lý như tăng cường tương phản, chuẩn hóa kích thước ảnh và xử lý mất cân bằng dữ liệu có ảnh hưởng đáng kể đến hiệu quả phân loại. Bên cạnh đó, việc sử dụng nhiều chỉ số đánh giá như macro-F1, QWK, AUC và confusion matrix là cần thiết để phản ánh đầy đủ hơn chất lượng mô hình, đặc biệt trong bối cảnh dữ liệu giữa các lớp bệnh không đồng đều.

Dựa trên những nhận xét đó, đề tài lựa chọn hướng tiếp cận sử dụng hai mô hình CNN là DenseNet121 và EfficientNetB3 để phân loại ảnh đáy mắt thành 5 mức độ bệnh võng mạc đái tháo đường. DenseNet121 được lựa chọn nhờ khả năng tái sử dụng đặc trưng thông qua các kết nối dày đặc giữa các lớp, trong khi EfficientNetB3 được lựa chọn vì có khả năng cân bằng giữa hiệu quả học đặc trưng và chi phí tính toán. Trước khi đưa ảnh vào mô hình, đề tài áp dụng pipeline tiền xử lý gồm crop viền đen, tăng cường tương phản bằng CLAHE, resize ảnh về 320×320 và chuẩn hóa ảnh theo từng backbone. Quy trình này được xây dựng nhằm tạo dữ liệu đầu vào ổn định hơn, đồng thời hạn chế các yếu tố không liên quan đến vùng võng mạc.

Sau khi huấn luyện riêng từng mô hình, đề tài kết hợp xác suất đầu ra của DenseNet121 và EfficientNetB3 bằng phương pháp ensemble weighted average. Kết quả dự đoán cuối cùng được xác định bằng cách chọn lớp có xác suất cao nhất sau khi kết hợp. Ngoài việc đánh giá mô hình bằng các chỉ số định lượng, đề tài còn chú ý đến khả năng trình bày kết quả trên hệ thống web. Cụ thể, hệ thống không chỉ hiển thị nhãn dự đoán mà còn hiển thị xác suất từng lớp, kết quả từng mô hình, kết quả ensemble, ảnh sau tiền xử lý, heatmap giải thích và cảnh báo khi mô hình chưa chắc chắn giữa các mức bệnh lân cận. Định hướng này giúp đề tài không chỉ dừng ở việc xây dựng mô hình phân loại mà còn phát triển thành một hệ thống hỗ trợ tham khảo có tính minh họa và dễ sử dụng trong phạm vi nghiên cứu học thuật.

Như vậy, phương pháp của đề tài được hình thành từ ba thành phần chính: tiền xử lý ảnh đáy mắt, phân loại bằng hai mô hình CNN và kết hợp kết quả bằng ensemble weighted average. Các thành phần này sẽ được cụ thể hóa trong các chương tiếp theo,

bao gồm phân tích thiết kế hệ thống, xây dựng mô hình, huấn luyện thực nghiệm, đánh giá kết quả và triển khai ứng dụng web.

CHƯƠNG 3

PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG HỖ TRỢ DỰ ĐOÁN

3.1. Tổng quan hệ thống đề xuất

Hệ thống được xây dựng trong đề tài là một ứng dụng web hỗ trợ phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt. Người dùng có thể tải ảnh fundus lên hệ thống, sau đó ảnh được chuyển đến bộ phận xử lý để thực hiện các bước tiền xử lý cần thiết trước khi đưa vào mô hình học sâu. Sau quá trình suy luận, hệ thống trả về kết quả dự đoán mức độ bệnh, xác suất dự đoán, xác suất của từng lớp, ảnh gốc, ảnh sau tiền xử lý và heatmap giải thích. Việc xây dựng hệ thống web giúp mô hình không chỉ dừng lại ở kết quả huấn luyện trên tập dữ liệu, mà còn có thể được kiểm thử thông qua một giao diện trực quan, dễ thao tác và phù hợp với mục tiêu minh họa khả năng ứng dụng của mô hình trong thực tế.

Về mặt tổng thể, hệ thống gồm ba thành phần chính là giao diện người dùng, backend xử lý và mô hình trí tuệ nhân tạo. Giao diện người dùng đảm nhiệm việc tiếp nhận ảnh đầu vào và hiển thị kết quả dự đoán. Backend giữ vai trò trung gian, có nhiệm vụ nhận ảnh từ giao diện, kiểm tra dữ liệu đầu vào, thực hiện tiền xử lý, gọi mô hình AI để dự đoán và gửi kết quả về lại cho người dùng. Thành phần mô hình AI sử dụng hai mô hình DenseNet121 và EfficientNetB3 đã được huấn luyện trước, sau đó kết hợp xác suất đầu ra bằng phương pháp ensemble weighted average để đưa ra kết quả cuối cùng cho 5 mức độ bệnh gồm No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Bên cạnh nhãn dự đoán cuối cùng, hệ thống còn hiển thị độ tin cậy và cảnh báo trong những trường hợp mô hình chưa chắc chắn, đặc biệt khi xác suất giữa các lớp bệnh lân cận gần nhau. Cách thiết kế này giúp hệ thống vừa thể hiện được kết quả của mô hình phân loại, vừa nhấn mạnh rằng kết quả chỉ mang tính hỗ trợ tham khảo và không thay thế cho chẩn đoán của bác sĩ chuyên khoa.

3.2. Yêu cầu hệ thống

Yêu cầu hệ thống được xác định dựa trên mục tiêu chính của đề tài là xây dựng một hệ thống hỗ trợ dự đoán mức độ bệnh võng mạc đái tháo đường từ ảnh đáy mắt. Hệ thống không tập trung vào việc phát triển đầy đủ các chức năng của một phần mềm y tế chuyên nghiệp, mà chủ yếu phục vụ việc kiểm thử và trình bày kết quả của mô hình AI sau khi huấn luyện. Vì vậy, các yêu cầu được xây dựng theo hướng đơn giản, rõ ràng và bám sát quy trình xử lý ảnh: người dùng tải ảnh đầu vào, hệ thống xử lý ảnh, mô hình đưa ra dự đoán và kết quả được hiển thị lại trên giao diện.

3.2.1. Yêu cầu chức năng

Về chức năng, hệ thống cần cho phép người dùng tải ảnh đáy mắt từ thiết bị cá nhân lên giao diện web. Sau khi nhận ảnh, hệ thống thực hiện kiểm tra định dạng ảnh, xử lý ảnh đầu vào và đưa ảnh vào mô hình AI để dự đoán. Kết quả trả về cần thể hiện

được mức độ bệnh được dự đoán theo 5 lớp gồm No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Bên cạnh nhân dự đoán cuối cùng, hệ thống cần hiển thị xác suất dự đoán của từng lớp để người dùng có thể quan sát mức độ chắc chắn của mô hình, thay vì chỉ nhận một kết quả phân loại duy nhất.

Ngoài kết quả dự đoán, hệ thống cần hiển thị thêm ảnh gốc, ảnh sau tiền xử lý và heatmap giải thích. Ảnh gốc giúp người dùng đối chiếu với dữ liệu ban đầu, ảnh sau tiền xử lý cho thấy dữ liệu thực tế được đưa vào mô hình, còn heatmap hỗ trợ trực quan hóa vùng ảnh có ảnh hưởng đến quyết định phân loại. Hệ thống cũng cần có chức năng hiển thị cảnh báo trong một số trường hợp đặc biệt, chẳng hạn khi mô hình có độ tin cậy thấp hoặc khi xác suất giữa hai lớp bệnh lân cận gần nhau. Những chức năng này giúp kết quả dự đoán được trình bày đầy đủ hơn và phù hợp hơn với bối cảnh ảnh y tế.

Bảng 3. 1. Các yêu cầu chức năng chính của hệ thống.

STT	Yêu cầu chức năng	Mô tả
1	Tải ảnh đáy mắt	Cho phép người dùng chọn và tải ảnh fundus lên hệ thống
2	Kiểm tra ảnh đầu vào	Kiểm tra định dạng ảnh và khả năng đọc ảnh
3	Tiền xử lý ảnh	Thực hiện các bước xử lý trước khi đưa ảnh vào mô hình
4	Dự đoán mức độ bệnh	Phân loại ảnh thành 5 mức độ bệnh võng mạc đái tháo đường
5	Hiển thị xác suất	Hiển thị xác suất dự đoán của từng lớp bệnh
6	Hiển thị ảnh minh họa	Hiển thị ảnh gốc, ảnh sau tiền xử lý và heatmap
7	Cảnh báo kết quả	Cảnh báo khi độ tin cậy thấp hoặc xác suất giữa các lớp bệnh gần nhau

3.2.2. Yêu cầu phi chức năng

Về yêu cầu phi chức năng, hệ thống cần có giao diện đơn giản, dễ sử dụng và phù hợp với người dùng không chuyên về kỹ thuật. Người dùng chỉ cần thực hiện thao tác chọn ảnh và gửi ảnh để hệ thống dự đoán, sau đó kết quả cần được trình bày rõ ràng, dễ quan sát và không gây hiểu nhầm về ý nghĩa y tế. Do hệ thống có liên quan đến bài toán hỗ trợ chẩn đoán, phần hiển thị kết quả cần nhấn mạnh rằng dự đoán của

mô hình chỉ mang tính tham khảo, không thay thế cho kết luận của bác sĩ chuyên khoa.

Bên cạnh đó, hệ thống cần đảm bảo hoạt động ổn định trong môi trường thử nghiệm, có thời gian phản hồi hợp lý và có khả năng xử lý lỗi cơ bản khi ảnh đầu vào không hợp lệ. Cấu trúc hệ thống cũng cần được tổ chức theo hướng tách biệt giữa giao diện, backend và mô hình AI để thuận tiện cho việc kiểm thử, bảo trì hoặc thay thế mô hình trong tương lai. Trong phạm vi đề tài, các yêu cầu phi chức năng được đặt ở mức phù hợp với một hệ thống nghiên cứu, tập trung vào tính ổn định, tính minh bạch và khả năng trình bày kết quả của mô hình.

Bảng 3. 2. Các yêu cầu phi chức năng chính của hệ thống.

STT	Yêu cầu phi chức năng	Mô tả
1	Dễ sử dụng	Giao diện đơn giản, thao tác tải ảnh và xem kết quả rõ ràng
2	Thời gian phản hồi hợp lý	Hệ thống trả kết quả sau khi người dùng tải ảnh lên
3	Tính ổn định	Hệ thống có thể hoạt động ổn định trong môi trường thử nghiệm
4	Tính minh bạch	Hiển thị xác suất, ảnh tiền xử lý và heatmap giải thích
5	Khả năng mở rộng	Có thể cập nhật hoặc thay thế mô hình AI trong tương lai
6	Xử lý lỗi cơ bản	Thông báo khi ảnh không hợp lệ hoặc không thể xử lý
7	Giới hạn sử dụng	Nhấn mạnh kết quả chỉ hỗ trợ tham khảo, không thay thế chẩn đoán y tế

3.3. Quy trình hoạt động của hệ thống

Quy trình hoạt động của hệ thống bắt đầu từ thao tác tải ảnh đầy mắt của người dùng trên giao diện web. Sau khi người dùng chọn ảnh và gửi yêu cầu dự đoán, ảnh sẽ được chuyển đến backend để kiểm tra và xử lý. Ở bước này, hệ thống kiểm tra định dạng ảnh, khả năng đọc ảnh và tính hợp lệ cơ bản của dữ liệu đầu vào. Nếu ảnh không đúng định dạng hoặc không thể xử lý, hệ thống sẽ trả về thông báo lỗi để người dùng kiểm tra lại ảnh. Nếu ảnh hợp lệ, backend tiếp tục thực hiện các bước tiền xử lý nhằm đưa ảnh về dạng phù hợp với mô hình học sâu.


Sau khi tiền xử lý, ảnh được đưa vào hai mô hình DenseNet121 và EfficientNetB3 đã được huấn luyện trước. Mỗi mô hình trả về một vector xác suất tương ứng với 5 mức độ bệnh võng mạc đái tháo đường. Các vector xác suất này được kết hợp bằng phương pháp ensemble weighted average để tạo ra kết quả dự đoán cuối cùng. Lớp có xác suất cao nhất sau khi kết hợp được chọn làm nhãn dự đoán của hệ thống. Ngoài nhãn dự đoán, hệ thống cũng lưu lại xác suất của từng lớp để hiển thị cho người dùng, giúp người dùng quan sát được mức độ chắc chắn của mô hình đối với từng khả năng phân loại.

Sau khi có kết quả dự đoán, backend tạo dữ liệu phản hồi gồm nhãn bệnh, xác suất dự đoán, ảnh sau tiền xử lý, heatmap giải thích và các cảnh báo nếu có. Những dữ liệu này được gửi về frontend để hiển thị trên giao diện web. Người dùng có thể xem ảnh gốc, ảnh sau xử lý, heatmap và kết quả phân loại trên cùng một màn hình. Quy trình này giúp hệ thống thể hiện được đầy đủ các bước từ dữ liệu đầu vào đến kết quả đầu ra, đồng thời giúp người dùng hiểu rằng kết quả dự đoán của mô hình chỉ mang tính hỗ trợ tham khảo và cần được xem xét thận trọng trong bối cảnh y tế.

Luồng xử lý chính của hệ thống gồm các bước: người dùng tải ảnh đáy mắt, hệ thống kiểm tra ảnh đầu vào, thực hiện tiền xử lý, đưa ảnh vào hai mô hình CNN, kết hợp kết quả bằng ensemble, sinh heatmap giải thích, trả kết quả dự đoán và hiển thị cảnh báo y tế nếu cần. Quy trình này được thiết kế theo hướng rõ ràng, dễ kiểm tra và phù hợp với mục tiêu của đề tài là xây dựng một hệ thống minh họa khả năng ứng dụng mô hình AI vào phân loại bệnh võng mạc đái tháo đường.

3.4. Kiến trúc tổng thể của hệ thống

Hệ thống hỗ trợ dự đoán bệnh võng mạc đái tháo đường từ ảnh đáy mắt được xây dựng theo mô hình web ứng dụng, trong đó các thành phần chính gồm giao diện người dùng, máy chủ xử lý và mô hình trí tuệ nhân tạo. Người dùng truy cập hệ thống thông qua trình duyệt web, sau đó tải ảnh đáy mắt lên giao diện để gửi yêu cầu dự đoán. Ảnh đầu vào được chuyển đến backend để kiểm tra định dạng, đọc dữ liệu ảnh và thực hiện các bước xử lý cần thiết trước khi đưa vào mô hình. Trong trường hợp ảnh không hợp lệ, không đúng định dạng hoặc không thể xử lý, hệ thống sẽ trả về thông báo để người dùng kiểm tra và tải lại ảnh khác. Nếu ảnh hợp lệ, backend tiến hành tiền xử lý nhằm chuẩn hóa ảnh đầu vào, bao gồm loại bỏ vùng không cần thiết, cải thiện chất lượng ảnh ở mức phù hợp, thay đổi kích thước và chuẩn hóa dữ liệu theo yêu cầu của mô hình học sâu. Sau đó, ảnh đã xử lý được đưa vào thành phần mô hình AI để thực hiện suy luận. Cách tổ chức này giúp hệ thống tách biệt rõ giữa phần giao diện, phần xử lý nghiệp vụ và phần mô hình, từ đó thuận tiện hơn cho việc kiểm thử, bảo trì và mở rộng trong tương lai.



Hình 3. 1. Kiến trúc tổng thể hệ thống.

Thành phần mô hình AI trong hệ thống sử dụng hai mô hình học sâu đã được huấn luyện trước là DenseNet121 và EfficientNetB3. Khi một ảnh đáy mắt được đưa vào hệ thống, mỗi mô hình sẽ trả về một vector xác suất gồm 5 giá trị tương ứng với 5 mức độ bệnh: No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Các kết quả này không được sử dụng riêng lẻ mà được kết hợp bằng phương pháp ensemble weighted average, trong đó DenseNet121 có trọng số 0,45 và EfficientNetB3 có trọng số 0,55. Sau khi kết hợp, lớp có xác suất cao nhất được chọn làm kết quả dự đoán cuối cùng của hệ thống. Bên cạnh nhãn dự đoán, backend còn tổng hợp các thông tin phục vụ hiển thị như xác suất của từng lớp bệnh, ảnh gốc, ảnh sau tiền xử lý, heatmap giải thích và các cảnh báo y tế nếu có. Các thông tin này sau đó được trả về giao diện để người dùng quan sát trên cùng một màn hình. Với kiến trúc này, hệ thống không chỉ thể hiện được kết quả phân loại của mô hình mà còn cung cấp thêm các thông tin hỗ trợ giúp người dùng hiểu rõ hơn về mức độ chắc chắn của dự đoán. Đồng thời, việc hiển thị heatmap và cảnh báo giúp nhấn mạnh rằng kết quả của mô hình chỉ mang tính hỗ trợ tham khảo, không thay thế cho chẩn đoán của bác sĩ chuyên khoa.

3.5. Thiết kế dữ liệu đầu vào và kết quả đầu ra

Dữ liệu đầu vào của hệ thống là ảnh đáy mắt được người dùng tải lên từ thiết bị cá nhân. Ảnh có thể ở các định dạng thông dụng như JPG, JPEG hoặc PNG, nhưng cần đảm bảo có thể đọc được và thể hiện rõ vùng võng mạc để mô hình có đủ thông tin phục vụ quá trình dự đoán. Trong trường hợp ảnh bị lỗi, ảnh không đúng định dạng, ảnh quá mờ hoặc không phải ảnh đáy mắt, kết quả dự đoán có thể không đáng tin cậy. Vì vậy, hệ thống cần kiểm tra dữ liệu đầu vào ở mức cơ bản trước khi đưa vào mô hình. Sau khi ảnh hợp lệ được tiếp nhận, hệ thống thực hiện các bước tiền xử lý như cắt vùng viền đen, tăng cường tương phản, thay đổi kích thước về 320×320 và chuẩn hóa ảnh theo yêu cầu của mô hình học sâu. Ảnh sau tiền xử lý là dữ liệu chính được sử dụng cho quá trình suy luận của hai mô hình DenseNet121 và EfficientNetB3.

Kết quả đầu ra của hệ thống được thiết kế nhằm cung cấp cho người dùng không chỉ nhãn dự đoán cuối cùng mà còn các thông tin hỗ trợ để hiểu rõ hơn về dự đoán của mô hình. Kết quả chính là một trong năm mức độ bệnh võng mạc đái tháo đường, gồm No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Bên cạnh đó, hệ thống hiển thị xác suất của từng lớp bệnh để thể hiện mức độ chắc chắn của mô hình đối với từng khả năng phân loại. Việc hiển thị xác suất từng lớp là cần thiết vì trong một số trường hợp, mô hình có thể dự đoán đúng lớp có xác suất cao nhất nhưng vẫn có sự chênh lệch nhỏ với các lớp lân cận. Điều này đặc biệt quan trọng đối với các lớp bệnh gần nhau về mức độ, chẳng hạn Moderate DR và Severe DR.

Ngoài kết quả phân loại, hệ thống còn hiển thị ảnh gốc, ảnh sau tiền xử lý và heatmap giải thích. Ảnh gốc giúp người dùng đối chiếu với dữ liệu ban đầu đã tải lên, trong khi ảnh sau tiền xử lý cho thấy dạng ảnh được mô hình sử dụng để suy luận.

Heatmap được dùng để trực quan hóa vùng ảnh có ảnh hưởng nhiều đến quyết định của mô hình, giúp kết quả dự đoán trở nên dễ quan sát hơn. Tuy nhiên, heatmap chỉ có ý nghĩa hỗ trợ giải thích, không phải là kết quả phân đoạn tổn thương y khoa. Trong các trường hợp mô hình có độ tin cậy thấp hoặc xác suất giữa hai lớp bệnh lân cận gần nhau, hệ thống sẽ hiển thị thêm cảnh báo để nhấn mạnh rằng kết quả chỉ nên được sử dụng như một thông tin tham khảo.

Bảng 3. 3. Các thành phần dữ liệu đầu vào và kết quả đầu ra của hệ thống.

Thành phần	Nội dung	Vai trò trong hệ thống
Ảnh đầu vào	Ảnh đáy mắt định dạng JPG, JPEG hoặc PNG	Dữ liệu ban đầu do người dùng tải lên
Ảnh sau tiền xử lý	Ảnh đã được crop viền đen, tăng cường tương phản, resize và chuẩn hóa	Dữ liệu được đưa vào mô hình học sâu
Nhãn dự đoán	No DR, Mild DR, Moderate DR, Severe DR hoặc Proliferative DR	Kết quả phân loại chính của hệ thống
Xác suất từng lớp	Xác suất tương ứng với 5 mức độ bệnh	Thể hiện mức độ chắc chắn của mô hình
Heatmap giải thích	Bản đồ trực quan vùng ảnh ảnh hưởng đến dự đoán	Hỗ trợ giải thích kết quả mô hình
Cảnh báo	Cảnh báo độ tin cậy thấp hoặc lớp bệnh lân cận gần nhau	Giúp người dùng hiểu giới hạn của kết quả dự đoán

3.6. Cảnh báo y tế và giới hạn sử dụng của hệ thống

Do hệ thống được xây dựng trong phạm vi đề tài nghiên cứu, kết quả dự đoán chỉ có ý nghĩa hỗ trợ tham khảo và không được xem là kết luận chẩn đoán y khoa. Bệnh võng mạc đái tháo đường là bệnh lý cần được đánh giá bởi bác sĩ chuyên khoa mắt dựa trên nhiều yếu tố khác nhau, trong khi hệ thống của đề tài chỉ sử dụng ảnh đáy mắt làm dữ liệu đầu vào. Vì vậy, trong quá trình thiết kế hệ thống, phần cảnh báo y tế được xem là một thành phần cần thiết nhằm giúp người dùng hiểu rõ giới hạn của mô hình. Khi hiển thị kết quả, hệ thống cần nhấn mạnh rằng dự đoán của AI không thay thế cho việc thăm khám, tư vấn và kết luận của bác sĩ. Điều này đặc biệt quan trọng trong các trường hợp ảnh đầu vào có chất lượng thấp, ảnh bị mờ, ảnh thiếu sáng, vùng võng mạc không rõ hoặc mô hình đưa ra kết quả với độ tin cậy chưa cao.

Một cảnh báo chính của hệ thống là cảnh báo khi độ tin cậy của dự đoán thấp. Trong trường hợp xác suất cao nhất của mô hình không vượt qua ngưỡng tin cậy được thiết lập, hệ thống sẽ thông báo rằng kết quả dự đoán chưa đủ chắc chắn và người dùng nên tham khảo ý kiến bác sĩ chuyên khoa. Ngoài ra, hệ thống cũng cần cảnh báo khi xác suất giữa các lớp bệnh lân cận có sự chênh lệch nhỏ, đặc biệt là giữa Moderate

DR và Severe DR. Đây là hai mức bệnh có thể gây nhầm lẫn vì đặc trưng tổn thương trên ảnh đáy mắt có sự chuyển tiếp về mức độ. Nếu mô hình cho xác suất của hai lớp này gần nhau, việc chỉ hiển thị một nhãn dự đoán duy nhất có thể làm người dùng hiểu sai về mức độ chắc chắn của kết quả. Do đó, cảnh báo trong trường hợp này giúp thể hiện tính thận trọng của hệ thống khi làm việc với dữ liệu ảnh y tế.

Bên cạnh cảnh báo về xác suất dự đoán, hệ thống cũng cần làm rõ ý nghĩa của heatmap giải thích. Heatmap chỉ biểu diễn vùng ảnh có ảnh hưởng đến quyết định của mô hình, không phải là kết quả phân đoạn tổn thương võng mạc. Nói cách khác, vùng nổi bật trên heatmap không khẳng định chắc chắn đó là vùng tổn thương y khoa, mà chỉ cho thấy mô hình đã chú ý nhiều hơn đến vùng đó khi đưa ra dự đoán. Vì vậy, heatmap trong hệ thống chỉ được sử dụng như một công cụ hỗ trợ trực quan, giúp người dùng quan sát thêm thông tin về quá trình suy luận của mô hình. Việc kết hợp nhãn dự đoán, xác suất từng lớp, heatmap và cảnh báo y tế giúp hệ thống trình bày kết quả một cách thận trọng hơn, phù hợp với mục tiêu xây dựng công cụ hỗ trợ tham khảo trong phạm vi nghiên cứu.

Bảng 3. 4. Một số trường hợp cảnh báo được sử dụng trong hệ thống.

STT	Trường hợp cảnh báo	Ý nghĩa
1	Độ tin cậy dự đoán thấp	Mô hình chưa thật sự chắc chắn với kết quả cuối cùng
2	Xác suất giữa Moderate DR và Severe DR gần nhau	Có khả năng nhầm lẫn giữa hai mức bệnh lân cận
3	Ảnh đầu vào không hợp lệ hoặc không thể xử lý	Ảnh không phù hợp để đưa vào mô hình dự đoán
4	Heatmap chỉ mang tính giải thích	Heatmap không phải là kết quả phân đoạn tổn thương y khoa
5	Kết quả chỉ mang tính tham khảo	Người dùng cần tham khảo ý kiến bác sĩ chuyên khoa khi cần kết luận y tế

CHƯƠNG 4

XÂY DỰNG MÔ HÌNH PHÂN LOẠI BỆNH VÕNG MẠC ĐÁI THÁO ĐƯỜNG

4.1. Tập dữ liệu sử dụng trong đề tài

4.1.1. Giới thiệu tập dữ liệu APTOS 2019

Trong đề tài này, tập dữ liệu được sử dụng để huấn luyện và đánh giá mô hình là APTOS 2019 Blindness Detection. Đây là tập dữ liệu ảnh đáy mắt được công bố trong cuộc thi trên nền tảng Kaggle, với mục tiêu xây dựng mô hình có khả năng phát hiện và phân loại mức độ bệnh võng mạc đái tháo đường từ ảnh fundus. Tập dữ liệu này phù hợp với hướng nghiên cứu của đề tài vì mỗi ảnh được gán nhãn theo mức độ bệnh, tương ứng với bài toán phân loại đa lớp. Thay vì chỉ xác định ảnh có bệnh hay không có bệnh, mô hình trong đề tài cần phân loại ảnh thành 5 mức độ khác nhau, gồm No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR [9].

APTOS 2019 được lựa chọn vì đây là một tập dữ liệu công khai, phổ biến trong nhiều nghiên cứu về phân loại bệnh võng mạc đái tháo đường bằng học sâu. Ảnh trong tập dữ liệu được chụp trong điều kiện thực tế nên có sự khác biệt về độ sáng, độ tương phản, kích thước vùng võng mạc và chất lượng ảnh. Điều này làm cho bài toán trở nên gần với thực tế hơn, nhưng đồng thời cũng tạo ra nhiều khó khăn trong quá trình huấn luyện mô hình. Một số ảnh có thể tồn tại vùng viền đen lớn, ánh sáng không đồng đều hoặc chi tiết võng mạc chưa rõ, vì vậy bước tiền xử lý ảnh là cần thiết trước khi đưa dữ liệu vào mô hình học sâu.

4.1.2. Cấu trúc dữ liệu


Tập dữ liệu APTOS 2019 gồm các ảnh đáy mắt và tệp nhãn đi kèm. Mỗi ảnh trong tập huấn luyện được xác định bằng một mã ảnh và một nhãn chẩn đoán tương ứng. Nhãn của ảnh được biểu diễn bằng số nguyên từ 0 đến 4, trong đó 0 tương ứng với No DR, 1 tương ứng với Mild DR, 2 tương ứng với Moderate DR, 3 tương ứng với Severe DR và 4 tương ứng với Proliferative DR. Cấu trúc nhãn này phù hợp với bài toán phân loại có tính thứ bậc, vì các lớp bệnh thể hiện mức độ tiến triển tăng dần của bệnh võng mạc đái tháo đường.

Trong quá trình xây dựng mô hình, ảnh và nhãn được đọc từ tập dữ liệu để tạo thành bộ dữ liệu huấn luyện và kiểm tra. Ảnh đầu vào trước khi đưa vào mô hình không được sử dụng trực tiếp ở dạng ban đầu, mà được xử lý qua các bước như cắt vùng viền đen, tăng cường tương phản, thay đổi kích thước và chuẩn hóa. Việc thống nhất kích thước và định dạng ảnh giúp mô hình có thể học ổn định hơn, đồng thời giảm ảnh hưởng của các yếu tố không liên quan như nền đen hoặc kích thước ảnh

không đồng nhất. Sau khi tiền xử lý, ảnh được đưa vào hai mô hình DenseNet121 và EfficientNetB3 để phục vụ quá trình huấn luyện và đánh giá.

4.1.3. Phân bố các lớp bệnh

Một đặc điểm quan trọng của tập dữ liệu APTOS 2019 là sự mất cân bằng giữa các lớp bệnh. Trong thực tế, số lượng ảnh ở lớp No DR thường nhiều hơn đáng kể so với các lớp bệnh nặng như Severe DR hoặc Proliferative DR. Sự mất cân bằng này có thể ảnh hưởng đến quá trình huấn luyện mô hình, vì mô hình có xu hướng học tốt hơn ở các lớp có nhiều mẫu và dự đoán kém hơn ở các lớp có ít mẫu. Đối với bài toán phân loại bệnh võng mạc đái tháo đường, đây là vấn đề cần được quan tâm vì các lớp bệnh nặng tuy có ít ảnh hơn nhưng lại có ý nghĩa quan trọng trong hỗ trợ sàng lọc.



Hình 4. 1. Ảnh minh họa ảnh đáy mắt thuộc 5 mức độ bệnh

Trong đề tài, sự mất cân bằng dữ liệu được xem là một trong những nguyên nhân ảnh hưởng đến kết quả phân loại, đặc biệt ở lớp Severe DR. Khi số lượng mẫu của một lớp ít hơn, mô hình có thể gặp khó khăn trong việc học đầy đủ các đặc trưng đại diện cho lớp đó. Điều này dẫn đến khả năng nhầm lẫn giữa các lớp bệnh lân cận, chẳng hạn giữa Moderate DR và Severe DR. Vì vậy, khi đánh giá mô hình, đề tài không chỉ sử dụng accuracy mà còn xem xét thêm các chỉ số như macro-F1, recall theo từng lớp, Quadratic Weighted Kappa và confusion matrix để phân tích chi tiết hơn hiệu quả phân loại.


Bảng 4. 1. Ý nghĩa các nhãn trong tập dữ liệu APTOS 2019.

Nhãn	Tên lớp	Ý nghĩa
0	No DR	Không có dấu hiệu bệnh võng mạc đái tháo đường
1	Mild DR	Bệnh võng mạc đái tháo đường mức độ nhẹ
2	Moderate DR	Bệnh võng mạc đái tháo đường mức độ trung bình
3	Severe DR	Bệnh võng mạc đái tháo đường mức độ nặng
4	Proliferative DR	Bệnh võng mạc đái tháo đường tăng sinh

4.2. Quy trình tiền xử lý dữ liệu

Trước khi đưa ảnh đáy mắt vào mô hình học sâu, dữ liệu cần được tiền xử lý để giảm bớt các yếu tố gây nhiễu và đưa ảnh về cùng một định dạng đầu vào. Ảnh trong tập dữ liệu APTOS 2019 được chụp trong nhiều điều kiện khác nhau nên có sự khác biệt về kích thước, độ sáng, độ tương phản, vùng viền đen xung quanh võng mạc và chất lượng hiển thị chi tiết trên ảnh. Nếu sử dụng trực tiếp ảnh gốc, mô hình có thể học cả những đặc điểm không liên quan đến bệnh, chẳng hạn vùng nền đen hoặc sự khác biệt về ánh sáng giữa các ảnh. Vì vậy, trong đề tài này, quy trình tiền xử lý được xây dựng nhằm chuẩn hóa ảnh đầu vào, giúp dữ liệu ổn định hơn trước khi đưa vào hai mô hình DenseNet121 và EfficientNetB3.

Quy trình tiền xử lý trong đề tài gồm bốn bước chính: cắt vùng viền đen, tăng cường tương phản bằng CLAHE, thay đổi kích thước ảnh về 320×320 và chuẩn hóa ảnh đầu vào. Trước hết, ảnh được xử lý để loại bỏ các vùng viền đen không chứa thông tin y khoa. Trong nhiều ảnh đáy mắt, vùng võng mạc chỉ nằm ở khu vực trung tâm, còn xung quanh là nền đen do đặc điểm của thiết bị chụp fundus. Phần nền này không có nhiều giá trị cho việc phân loại bệnh, nhưng nếu giữ lại quá nhiều có thể làm giảm khả năng tập trung của mô hình vào vùng võng mạc. Sau khi cắt viền đen, ảnh được tăng cường tương phản bằng CLAHE nhằm làm rõ hơn các chi tiết cục bộ như mạch máu và một số vùng bất thường trên võng mạc. CLAHE là phương pháp cân bằng histogram thích nghi có giới hạn tương phản, giúp cải thiện độ tương phản ảnh nhưng vẫn hạn chế việc khuếch đại nhiễu quá mức [23], [24].



Hình 4. 2. Quy trình tiền xử lý ảnh đáy mắt


Sau bước tăng cường tương phản, ảnh được thay đổi kích thước về 320×320 pixel để phù hợp với đầu vào của mô hình học sâu. Việc thống nhất kích thước ảnh là cần thiết vì DenseNet121 và EfficientNetB3 cần dữ liệu đầu vào có kích thước cố định trong quá trình huấn luyện và suy luận. Kích thước 320×320 được lựa chọn nhằm cân bằng giữa khả năng giữ lại thông tin quan trọng của ảnh đáy mắt và giới hạn tài nguyên tính toán khi huấn luyện mô hình. Nếu ảnh có kích thước quá nhỏ, một số chi tiết quan trọng có thể bị mất; ngược lại, nếu ảnh quá lớn, quá trình huấn luyện sẽ tốn nhiều bộ nhớ và thời gian hơn. Sau khi resize, ảnh được chuyển về dạng phù hợp với mô hình và chuẩn hóa theo yêu cầu của backbone tương ứng. Bước chuẩn

hóa giúp đưa giá trị điểm ảnh về miền giá trị ổn định hơn, hỗ trợ quá trình học của mô hình diễn ra hiệu quả hơn.

Trong phiên bản cuối cùng của đề tài, quy trình tiền xử lý được lựa chọn theo hướng đơn giản, ổn định và hạn chế làm thay đổi bản chất thông tin y khoa trong ảnh. Một số kỹ thuật nâng cao như siêu phân giải ảnh bằng ESRGAN không được sử dụng, mặc dù các kỹ thuật này có thể làm ảnh nhìn sắc nét hơn về mặt trực quan. Lý do là trong bài toán ảnh y tế, việc làm biến đổi hoặc tạo thêm chi tiết ảnh cần được kiểm chứng rất thận trọng, vì có thể ảnh hưởng đến cách mô hình học đặc trưng và cách người dùng diễn giải kết quả. Do đó, đề tài ưu tiên pipeline gồm crop viền đen, CLAHE, resize và chuẩn hóa ảnh. Sau khi hoàn tất các bước này, ảnh sau tiền xử lý được sử dụng làm đầu vào cho mô hình và cũng được hiển thị trên hệ thống web để người dùng có thể đối chiếu với ảnh gốc.

4.3. Xây dựng mô hình DenseNet121

Trong đề tài, DenseNet121 được sử dụng như một trong hai mô hình học sâu chính để phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt. DenseNet121 thuộc họ DenseNet, được thiết kế dựa trên ý tưởng kết nối dày đặc giữa các lớp trong mạng. Thay vì mỗi lớp chỉ nhận đầu vào từ lớp liền trước như một số kiến trúc CNN thông thường, DenseNet cho phép các lớp phía sau nhận thêm đặc trưng từ nhiều lớp phía trước. Cách kết nối này giúp mô hình tái sử dụng đặc trưng đã học, hỗ trợ quá trình lan truyền gradient và làm cho việc học đặc trưng trong mạng sâu ổn định hơn [19]. Đối với ảnh đáy mắt, mô hình cần nhận diện nhiều loại đặc trưng khác nhau, từ các cấu trúc tổng quát như vùng võng mạc, hệ thống mạch máu cho đến những vùng bất thường có thể liên quan đến bệnh. Vì vậy, DenseNet121 được lựa chọn để khai thác khả năng học và tái sử dụng đặc trưng trong quá trình phân loại ảnh fundus.




Hình 4. 3. Sơ đồ DenseNet121

Trong quá trình xây dựng mô hình, ảnh đáy mắt sau tiền xử lý được đưa về kích thước 320×320 và sử dụng làm đầu vào cho DenseNet121. Phần backbone của DenseNet121 đảm nhiệm vai trò trích xuất đặc trưng ảnh, sau đó các đặc trưng này được đưa qua phần phân loại để tạo ra xác suất dự đoán cho 5 lớp bệnh gồm No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Như vậy, đầu ra của mô hình không phải là kết quả nhị phân có bệnh hoặc không có bệnh, mà là vector xác suất tương ứng với 5 mức độ bệnh trong tập dữ liệu APTOS 2019 [9]. Sau khi huấn

luyện, DenseNet121 không được sử dụng độc lập làm kết quả cuối cùng của toàn hệ thống, mà đóng vai trò là một nhánh mô hình trong kiến trúc ensemble. Kết quả xác suất của DenseNet121 được kết hợp với kết quả của EfficientNetB3 bằng phương pháp ensemble weighted average, trong đó DenseNet121 có trọng số 0,45 và EfficientNetB3 có trọng số 0,55. Cách xây dựng này giúp hệ thống tận dụng được đặc trưng học được từ DenseNet121, đồng thời giảm sự phụ thuộc vào một mô hình đơn lẻ khi đưa ra dự đoán cuối cùng.

4.4. Xây dựng mô hình EfficientNetB3

EfficientNetB3 là mô hình học sâu thứ hai được sử dụng trong đề tài để phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt. EfficientNet thuộc nhóm các mô hình CNN được thiết kế theo hướng tối ưu sự cân bằng giữa độ sâu, độ rộng và độ phân giải đầu vào của mạng. Thay vì chỉ tăng riêng số lớp hoặc số kênh của mạng, EfficientNet sử dụng phương pháp compound scaling để mở rộng mô hình theo nhiều chiều một cách có hệ thống [20]. Trong đề tài này, EfficientNetB3 được lựa chọn vì có khả năng trích xuất đặc trưng tốt hơn so với các phiên bản nhỏ hơn, nhưng vẫn phù hợp với giới hạn tài nguyên huấn luyện trên môi trường thực nghiệm. Đối với ảnh đáy mắt, mô hình cần học được các đặc trưng thị giác phức tạp như cấu trúc mạch máu, vùng võng mạc, độ tương phản và những dấu hiệu bất thường có liên quan đến bệnh. Vì vậy, EfficientNetB3 được sử dụng như một backbone quan trọng nhằm bổ sung khả năng học đặc trưng cho hệ thống phân loại.



Hình 4. 4. Sơ đồ EfficientNetB3

Trong quá trình xây dựng mô hình, ảnh đáy mắt sau tiền xử lý được đưa về kích thước 320×320 trước khi đưa vào EfficientNetB3. Tương tự DenseNet121, phần backbone của EfficientNetB3 đảm nhiệm vai trò trích xuất đặc trưng ảnh, còn phần phân loại cuối được điều chỉnh để phù hợp với bài toán 5 lớp của tập dữ liệu APTOS 2019 [9]. Đầu ra của mô hình là vector xác suất gồm 5 giá trị tương ứng với các mức No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Trong hệ thống cuối cùng, EfficientNetB3 không hoạt động riêng lẻ mà được kết hợp với

DenseNet121 bằng phương pháp ensemble weighted average. Do EfficientNetB3 cho kết quả ổn định hơn trong quá trình thực nghiệm của đề tài, mô hình này được gán trọng số 0,55, trong khi DenseNet121 được gán trọng số 0,45. Việc sử dụng EfficientNetB3 trong ensemble giúp hệ thống tận dụng thêm đặc trưng từ một kiến trúc CNN khác, qua đó cải thiện tính ổn định của kết quả dự đoán so với việc chỉ sử dụng một mô hình đơn.

4.5. Kết hợp mô hình bằng ensemble weighted average

Sau khi xây dựng và huấn luyện riêng hai mô hình DenseNet121 và EfficientNetB3, đề tài không sử dụng một mô hình đơn lẻ để đưa ra kết quả cuối cùng mà kết hợp kết quả của hai mô hình bằng phương pháp ensemble weighted average. Trong hướng tiếp cận này, cùng một ảnh đáy mắt sau tiền xử lý sẽ được đưa lần lượt vào DenseNet121 và EfficientNetB3. Mỗi mô hình tạo ra một vector xác suất gồm 5 giá trị, tương ứng với 5 mức độ bệnh võng mạc đái tháo đường: No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Thay vì chọn trực tiếp kết quả từ một trong hai mô hình, hệ thống kết hợp hai vector xác suất này để tạo ra vector xác suất cuối cùng. Cách làm này giúp tận dụng đặc trưng học được từ hai kiến trúc CNN khác nhau, đồng thời giảm sự phụ thuộc vào kết quả của một mô hình duy nhất.


Trong đề tài, kết quả dự đoán cuối cùng được tính theo công thức:

$$P_{final} = 0,55 \times P_{EfficientNetB3} + 0,45 \times P_{DenseNet121}$$

Trong đó, $P_{EfficientNetB3}$ là vector xác suất đầu ra của mô hình EfficientNetB3, $P_{DenseNet121}$ là vector xác suất đầu ra của mô hình DenseNet121 và P_{final} là vector xác suất sau khi kết hợp. Sau khi có P_{final} , hệ thống chọn lớp có xác suất cao nhất làm nhãn dự đoán cuối cùng. Trọng số 0,55 cho EfficientNetB3 và 0,45 cho DenseNet121 được lựa chọn dựa trên quá trình thực nghiệm của đề tài, trong đó EfficientNetB3 được ưu tiên hơn một chút nhưng DenseNet121 vẫn được giữ lại để bổ sung thông tin đặc trưng. Phương pháp này không làm thay đổi cấu trúc bên trong của hai mô hình, mà chỉ kết hợp kết quả đầu ra sau khi từng mô hình đã hoàn tất quá trình suy luận.

Việc sử dụng ensemble weighted average phù hợp với mục tiêu của đề tài vì bài toán phân loại bệnh võng mạc đái tháo đường có nhiều lớp và một số lớp có đặc trưng gần nhau. Trong một số trường hợp, DenseNet121 và EfficientNetB3 có thể cho mức độ tin cậy khác nhau đối với cùng một ảnh đầu vào. Khi kết hợp xác suất của hai mô hình, kết quả cuối cùng có thể ổn định hơn so với việc chỉ dựa vào một mô hình riêng lẻ. Tuy nhiên, ensemble không loại bỏ hoàn toàn khả năng dự đoán sai, đặc biệt ở những trường hợp ảnh có chất lượng thấp hoặc xác suất giữa các lớp bệnh lân cận gần


nhau. Vì vậy, kết quả ensemble vẫn được trình bày kèm xác suất từng lớp và cảnh báo y tế trên hệ thống web để người dùng hiểu rõ hơn mức độ chắc chắn của dự đoán.



Hình 4. 5. Quy trình kết hợp mô hình bằng ensemble weighted average

4.6. Sinh heatmap giải thích kết quả dự đoán

Bên cạnh việc đưa ra nhãn dự đoán và xác suất của từng lớp bệnh, đề tài còn bổ sung heatmap giải thích nhằm trực quan hóa những vùng ảnh có ảnh hưởng đến quyết định của mô hình. Trong bài toán ảnh y tế, việc chỉ hiển thị kết quả phân loại cuối cùng là chưa đủ, vì người dùng khó biết mô hình đã dựa vào vùng nào trên ảnh để đưa ra dự đoán. Do đó, sau khi ảnh đáy mắt được tiền xử lý và đưa qua mô hình học sâu, hệ thống sinh thêm một bản đồ nhiệt để biểu diễn mức độ đóng góp của các vùng ảnh đối với kết quả dự đoán. Trong phiên bản cuối cùng của đề tài, heatmap được tạo theo hướng giải thích dựa trên mức đóng góp của điểm ảnh đối với đầu ra mô hình, cụ thể là phương pháp Integrated Gradients. Kết quả heatmap sau đó được chuẩn hóa và chồng lên ảnh đáy mắt để người dùng có thể quan sát trực quan hơn vùng ảnh mà mô hình chú ý trong quá trình phân loại.



Hình 4. 6. Sinh heatmap giải thích kết quả dự đoán

Heatmap trong đề tài được sử dụng như một thành phần hỗ trợ giải thích, không phải là kết quả phân đoạn tổn thương vĩnh viễn. Điều này có nghĩa là vùng nổi bật trên heatmap chỉ cho thấy khu vực có ảnh hưởng nhiều đến dự đoán của mô hình, chứ không khẳng định chắc chắn đó là vị trí tổn thương y khoa như xuất huyết, xuất tiết, vi phình mạch hay tân mạch. Vì vậy, khi hiển thị trên hệ thống web, heatmap được trình bày cùng với ảnh gốc, ảnh sau tiền xử lý, nhãn dự đoán và xác suất từng lớp để người dùng có thêm thông tin tham khảo. Cách trình bày này giúp kết quả của mô

hình trở nên minh bạch hơn, đồng thời vẫn giữ được sự thận trọng cần thiết khi ứng dụng AI trong phân tích ảnh y tế.

4.7. Lưu mô hình và tích hợp vào hệ thống web

Sau khi hoàn tất quá trình huấn luyện và lựa chọn phiên bản mô hình có kết quả tốt nhất, mô hình được lưu lại dưới dạng tệp trọng số để phục vụ cho giai đoạn đánh giá và tích hợp vào hệ thống web. Trong đề tài, mô hình cuối cùng sử dụng hai backbone DenseNet121 và EfficientNetB3, kết hợp kết quả bằng ensemble weighted average. Vì vậy, tệp mô hình cần lưu đầy đủ thông tin trọng số của hai nhánh mô hình để khi triển khai, hệ thống có thể tải lại mô hình và thực hiện suy luận trên ảnh mới mà không cần huấn luyện lại từ đầu. Cách lưu mô hình này giúp tách biệt giai đoạn huấn luyện và giai đoạn sử dụng mô hình, đồng thời thuận tiện cho việc kiểm thử trên môi trường web.

Khi tích hợp vào hệ thống, backend có nhiệm vụ tải mô hình đã huấn luyện, đưa mô hình về chế độ suy luận và tiếp nhận ảnh từ giao diện người dùng. Ảnh đầu vào sau khi được tải lên sẽ đi qua cùng quy trình tiền xử lý đã sử dụng trong quá trình huấn luyện, bao gồm crop viền đen, tăng cường tương phản, resize về 320×320 và chuẩn hóa ảnh. Việc giữ thống nhất quy trình tiền xử lý giữa huấn luyện và suy luận là cần thiết, vì nếu ảnh đầu vào khi triển khai được xử lý khác với ảnh trong giai đoạn huấn luyện thì kết quả dự đoán có thể bị ảnh hưởng. Sau khi ảnh được chuẩn hóa, backend đưa ảnh vào hai mô hình DenseNet121 và EfficientNetB3, lấy vector xác suất của từng mô hình, sau đó tính xác suất cuối cùng theo công thức ensemble đã xác định.

Kết quả sau khi suy luận không chỉ gồm nhãn dự đoán cuối cùng mà còn bao gồm xác suất từng lớp, ảnh sau tiền xử lý, heatmap giải thích và cảnh báo nếu có. Các thông tin này được backend đóng gói và trả về frontend để hiển thị cho người dùng. Nhờ đó, hệ thống web có thể minh họa đầy đủ quá trình sử dụng mô hình trong thực tế: người dùng tải ảnh đầy mắt, hệ thống xử lý ảnh, mô hình đưa ra dự đoán và giao diện hiển thị kết quả kèm các thông tin hỗ trợ. Việc tích hợp mô hình vào hệ thống web giúp đề tài không chỉ dừng lại ở kết quả huấn luyện trên tập dữ liệu, mà còn thể hiện được khả năng triển khai mô hình AI thành một công cụ.

CHƯƠNG 5

THỰC NGHIỆM, ĐÁNH GIÁ VÀ TRIỂN KHAI HỆ THỐNG

5.1. Môi trường và cấu hình thực nghiệm

Quá trình thực nghiệm của đề tài được thực hiện theo hai phần chính: huấn luyện mô hình học sâu và triển khai mô hình vào hệ thống web để kiểm thử dự đoán. Giai đoạn huấn luyện mô hình được thực hiện trên môi trường Kaggle Notebook nhằm tận dụng tài nguyên GPU có sẵn cho quá trình xử lý ảnh và huấn luyện mạng học sâu. Đây là môi trường phù hợp với đề tài vì tập dữ liệu APTOS 2019 được cung cấp trên Kaggle, giúp việc đọc dữ liệu, tiền xử lý ảnh, chia tập, huấn luyện và lưu kết quả thực nghiệm được thực hiện thuận tiện hơn. Ngôn ngữ lập trình chính được sử dụng là Python, kết hợp với các thư viện như PyTorch để xây dựng và huấn luyện mô hình, OpenCV để xử lý ảnh, NumPy và pandas để xử lý dữ liệu, scikit-learn để tính toán các chỉ số đánh giá, cùng matplotlib để trực quan hóa kết quả huấn luyện.

Trong quá trình huấn luyện, ảnh đầu vào được tiền xử lý theo cùng một quy trình gồm cắt vùng viền đen, tăng cường tương phản bằng CLAHE, thay đổi kích thước về 320×320 và chuẩn hóa dữ liệu trước khi đưa vào mô hình. Hai mô hình được sử dụng trong đề tài là DenseNet121 và EfficientNetB3, được huấn luyện để phân loại ảnh đáy mắt thành 5 mức độ bệnh võng mạc đái tháo đường gồm No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Sau khi huấn luyện, kết quả đầu ra của hai mô hình được kết hợp bằng phương pháp ensemble weighted average, trong đó EfficientNetB3 có trọng số 0,55 và DenseNet121 có trọng số 0,45. Việc sử dụng hai mô hình và kết hợp xác suất đầu ra nhằm tận dụng đặc trưng học được từ hai kiến trúc CNN khác nhau, đồng thời giúp kết quả dự đoán ổn định hơn so với việc chỉ sử dụng một mô hình đơn lẻ.

Sau khi quá trình huấn luyện hoàn tất, mô hình tốt nhất được lưu lại dưới dạng tệp trọng số để phục vụ cho giai đoạn đánh giá và triển khai thử nghiệm. Ở giai đoạn triển khai hệ thống web, backend được xây dựng bằng FastAPI để tiếp nhận ảnh từ người dùng, thực hiện tiền xử lý, gọi mô hình AI và trả kết quả dự đoán. Frontend được xây dựng bằng React và Vite nhằm cung cấp giao diện tải ảnh, hiển thị nhãn dự đoán, xác suất từng lớp, ảnh gốc, ảnh sau tiền xử lý và heatmap giải thích. Hệ thống được triển khai ở môi trường cục bộ trên máy tính cá nhân để phục vụ kiểm thử và trình bày kết quả nghiên cứu. Cách tổ chức này giúp tách biệt rõ giữa giai đoạn huấn luyện mô hình trên Kaggle và giai đoạn sử dụng mô hình trong hệ thống web, phù hợp với phạm vi của một đề tài khóa luận tập trung vào xây dựng mô hình AI và minh họa khả năng tích hợp mô hình vào ứng dụng thực tế.

Bảng 5. 1. Môi trường và cấu hình thực nghiệm chính của đề tài.

Thành phần	Cấu hình / công cụ sử dụng
Tập dữ liệu	APTOS 2019 Blindness Detection
Bài toán	Phân loại bệnh võng mạc đái tháo đường 5 lớp
Môi trường huấn luyện	Kaggle Notebook
Ngôn ngữ lập trình	Python
Framework học sâu	PyTorch
Thư viện xử lý ảnh	OpenCV
Thư viện xử lý dữ liệu	NumPy, pandas
Thư viện đánh giá	scikit-learn
Thư viện trực quan hóa	matplotlib
Kích thước ảnh đầu vào	320×320
Mô hình sử dụng	DenseNet121, EfficientNetB3
Phương pháp kết hợp	Ensemble weighted average
Trọng số ensemble	EfficientNetB3: 0,55; DenseNet121: 0,45
Backend	FastAPI
Frontend	React, Vite
Môi trường triển khai	Máy tính cá nhân, chạy cục bộ
Tệp mô hình sử dụng	hybrid_quality_fold0_best.pth

5.2. Kết quả huấn luyện và đánh giá mô hình

Sau quá trình huấn luyện trên tập dữ liệu APTOS 2019, đề tài thu được kết quả thực nghiệm của hai mô hình DenseNet121, EfficientNetB3 và mô hình kết hợp ensemble. Hai mô hình DenseNet121 và EfficientNetB3 được huấn luyện riêng trên cùng tập dữ liệu, cùng quy trình tiền xử lý ảnh và cùng bài toán phân loại 5 mức độ bệnh võng mạc đái tháo đường. Sau đó, xác suất đầu ra của hai mô hình được kết hợp bằng phương pháp ensemble weighted average, trong đó EfficientNetB3 có trọng số 0,55 và DenseNet121 có trọng số 0,45. Việc kết hợp được thực hiện ở mức xác suất đầu ra, do đó kết quả cuối cùng không phụ thuộc hoàn toàn vào một mô hình đơn lẻ mà tận dụng được thông tin dự đoán từ cả hai kiến trúc CNN.

Kết quả thực nghiệm cho thấy DenseNet121 đạt accuracy 81,09%, QWK 0,8892, macro-F1 0,6867 và AUC 0,9392. EfficientNetB3 cho kết quả accuracy cao

hơn, đạt 84,55%, QWK 0,8891, macro-F1 0,6795 và AUC 0,9494. Khi kết hợp hai mô hình bằng ensemble weighted average, kết quả cuối cùng đạt accuracy 84,73%, QWK 0,9042, macro-F1 0,7066 và AUC 0,9522. Có thể thấy mô hình ensemble không làm tăng accuracy quá nhiều so với EfficientNetB3, nhưng lại cải thiện rõ hơn ở các chỉ số quan trọng như QWK, macro-F1 và AUC. Điều này cho thấy việc kết hợp hai mô hình giúp kết quả dự đoán ổn định hơn, đặc biệt trong bài toán phân loại 5 mức độ bệnh có tính thứ bậc.

Trong các chỉ số đánh giá, accuracy phản ánh tỷ lệ dự đoán đúng tổng thể của mô hình, trong khi QWK có ý nghĩa quan trọng vì các mức độ bệnh vòng mạc đại tháo đường có quan hệ thứ bậc từ nhẹ đến nặng. Giá trị QWK của mô hình ensemble đạt 0,9042, cao hơn so với từng mô hình đơn lẻ, cho thấy kết quả dự đoán cuối cùng có mức độ phù hợp tốt hơn với nhãn thực tế. Bên cạnh đó, AUC của ensemble đạt 0,9522, cao hơn DenseNet121 và EfficientNetB3, thể hiện khả năng phân biệt giữa các lớp của mô hình kết hợp là tương đối tốt. Macro-F1 của ensemble đạt 0,7066, cao hơn hai mô hình đơn, cho thấy việc kết hợp mô hình có cải thiện hiệu quả trung bình trên các lớp.

Tuy nhiên, sự chênh lệch giữa accuracy và macro-F1 cũng cho thấy mô hình vẫn còn gặp khó khăn ở một số lớp bệnh ít mẫu hoặc có đặc trưng gần nhau. Đây là vấn đề thường gặp trong bài toán phân loại bệnh vòng mạc đại tháo đường 5 lớp, đặc biệt khi dữ liệu giữa các lớp không đồng đều. Vì vậy, ngoài việc xem xét các chỉ số tổng thể, đề tài tiếp tục phân tích confusion matrix và kết quả theo từng lớp ở mục sau để nhận diện rõ hơn những lớp mô hình dự đoán tốt và những lớp còn dễ nhầm lẫn.

Bảng 5. 2. Kết quả đánh giá của DenseNet121, EfficientNetB3 và mô hình ensemble trên tập kiểm tra.

Mô hình	Accuracy	QWK	Macro-F1	Weighted-F1	Macro Precision	Macro Recall	AUC
DenseNet121	81,09%	0,8892	0,6867	0,8159	0,6845	0,6973	0,939 2
EfficientNetB3	84,55%	0,8891	0,6795	0,8396	0,6968	0,6689	0,949 4
Ensemble	84,73%	0,9042	0,7066	0,8456	0,7147	0,7013	0,952 2

Từ bảng kết quả có thể nhận thấy EfficientNetB3 đạt accuracy cao hơn DenseNet121, nhưng mô hình ensemble đạt kết quả tổng thể tốt nhất ở nhiều chỉ số quan trọng. Cụ thể, ensemble có accuracy cao nhất, QWK cao nhất, macro-F1 cao nhất và AUC cao nhất trong ba phương án đánh giá. Vì vậy, mô hình ensemble được

lựa chọn làm mô hình chính để tích hợp vào hệ thống web hỗ trợ dự đoán bệnh võng mạc đái tháo đường.

5.3. Phân tích kết quả phân loại

Dựa trên kết quả đánh giá của mô hình ensemble, có thể thấy mô hình phân loại tốt nhất ở lớp No DR. Trong tổng số 271 ảnh thuộc lớp No DR, mô hình dự đoán đúng 266 ảnh, chỉ nhầm 4 ảnh sang Mild DR và 1 ảnh sang Moderate DR. Lớp này đạt precision 0,9925, recall 0,9815 và F1-score 0,9870, cho thấy mô hình nhận diện khá ổn định các ảnh không có dấu hiệu bệnh võng mạc đái tháo đường. Đây là kết quả hợp lý vì lớp No DR có số lượng ảnh nhiều nhất trong dữ liệu và đặc trưng hình ảnh thường khác biệt rõ hơn so với các lớp bệnh còn lại. Đối với lớp Mild DR, mô hình dự đoán đúng 40 trên 56 ảnh, đạt F1-score 0,6957. Một số ảnh Mild DR bị nhầm sang Moderate DR, cho thấy ranh giới giữa bệnh nhẹ và bệnh trung bình vẫn có thể gây khó khăn cho mô hình khi các dấu hiệu tổn thương trên ảnh chưa thật sự rõ ràng.

Ở lớp Moderate DR, mô hình dự đoán đúng 121 trên 150 ảnh, đạt precision 0,7610, recall 0,8067 và F1-score 0,7832. Đây là lớp có kết quả tương đối tốt sau No DR, tuy nhiên vẫn có một số ảnh bị nhầm sang Mild DR, Severe DR và Proliferative DR. Điều này cho thấy Moderate DR là lớp trung gian, có thể chứa các đặc trưng giao thoa với cả lớp nhẹ hơn và lớp nặng hơn. Đối với lớp Proliferative DR, mô hình dự đoán đúng 29 trên 44 ảnh, đạt F1-score 0,6824. Mặc dù số lượng ảnh của lớp này không nhiều, kết quả vẫn cho thấy mô hình có khả năng nhận diện một phần các trường hợp bệnh nặng. Tuy nhiên, vẫn còn một số ảnh Proliferative DR bị nhầm sang Moderate DR và Severe DR, phản ánh sự khó khăn khi phân biệt các mức độ bệnh nặng dựa trên ảnh đáy mắt.

Lớp có kết quả thấp nhất là Severe DR. Trong tổng số 29 ảnh thuộc lớp Severe DR, mô hình chỉ dự đoán đúng 10 ảnh, trong khi có 15 ảnh bị nhầm sang Moderate DR, 3 ảnh bị nhầm sang Proliferative DR và 1 ảnh bị nhầm sang Mild DR. Lớp Severe DR đạt precision 0,4348, recall 0,3448 và F1-score 0,3846. Kết quả này cho thấy mô hình còn gặp khó khăn đáng kể khi nhận diện Severe DR. Nguyên nhân có thể đến từ số lượng mẫu của lớp Severe DR ít hơn so với các lớp khác, đồng thời đặc trưng của lớp này có sự gần nhau với Moderate DR và Proliferative DR. Đây cũng là lý do trong hệ thống web, đề tài bổ sung cảnh báo khi xác suất giữa Moderate DR và Severe DR gần nhau, nhằm tránh việc người dùng hiểu kết quả dự đoán như một kết luận tuyệt đối.

Nhìn chung, mô hình ensemble đạt kết quả tốt ở lớp No DR và tương đối ổn ở lớp Moderate DR, trong khi các lớp Mild DR, Severe DR và Proliferative DR còn có mức độ nhầm lẫn nhất định. Điều này phù hợp với đặc điểm của bài toán phân loại bệnh võng mạc đái tháo đường 5 lớp, trong đó các lớp bệnh liên kế thường có đặc trưng hình ảnh chuyển tiếp và không phải lúc nào cũng tách biệt rõ ràng. Vì vậy, ngoài


các chỉ số tổng thể như accuracy, QWK và AUC, việc phân tích confusion matrix là cần thiết để nhìn rõ điểm mạnh và hạn chế của mô hình trên từng lớp bệnh. Kết quả phân tích này cũng là cơ sở để đề tài đưa ra cảnh báo y tế trong hệ thống, đặc biệt đối với những trường hợp mô hình chưa chắc chắn giữa các lớp bệnh lân cận.

Bảng 5. 3. Classification report của mô hình ensemble trên tập kiểm tra.

Lớp	Precision	Recall	F1-score	Số mẫu
No DR	0,9925	0,9815	0,9870	271
Mild DR	0,6780	0,7143	0,6957	56
Moderate DR	0,7610	0,8067	0,7832	150
Severe DR	0,4348	0,3448	0,3846	29
Proliferative DR	0,7073	0,6591	0,6824	44
Macro avg	0,7147	0,7013	0,7066	550
Weighted avg	0,8451	0,8473	0,8456	550

Bảng 5. 4. Ma trận nhầm lẫn của mô hình ensemble trên tập kiểm tra.

Nhãn thực tế \ Nhãn dự đoán	No DR	Mild DR	Moderate DR	Severe DR	Proliferative DR
No DR	266	4	1	0	0
Mild DR	0	40	15	0	1
Moderate DR	2	11	121	8	8
Severe DR	0	1	15	10	3
Proliferative DR	0	3	7	5	29



Hình 5. 1. Confusion matrix của mô hình ensemble trên tập kiểm tra.

5.4. Kết quả heatmap giải thích mô hình

Bên cạnh kết quả phân loại, hệ thống còn sinh heatmap nhằm hỗ trợ giải thích vùng ảnh có ảnh hưởng đến quyết định của mô hình. Sau khi ảnh đáy mắt được tiền xử lý và đưa qua mô hình AI, hệ thống tạo ra bản đồ nhiệt thể hiện mức độ đóng góp của các vùng ảnh đối với kết quả dự đoán. Heatmap được chồng lên ảnh đáy mắt để người dùng có thể quan sát trực quan hơn khu vực mà mô hình tập trung trong quá trình suy luận. Trong hệ thống web, heatmap được hiển thị cùng với ảnh gốc và ảnh sau tiền xử lý, giúp người dùng đối chiếu giữa dữ liệu đầu vào ban đầu, dữ liệu đã được xử lý và vùng ảnh có ảnh hưởng đến kết quả phân loại.

Kết quả heatmap cho thấy mô hình thường tập trung vào các vùng nằm trong khu vực võng mạc thay vì vùng nền đen xung quanh ảnh. Điều này cho thấy quy trình tiền xử lý ảnh có vai trò hỗ trợ mô hình tập trung hơn vào vùng chứa thông tin y khoa. Tuy nhiên, mức độ tập trung của heatmap có thể khác nhau tùy theo từng ảnh và từng mức độ bệnh. Với một số ảnh có chất lượng tốt, vùng heatmap thường rõ ràng hơn và nằm ở những khu vực có đặc điểm bất thường hoặc vùng có nhiều thông tin thị giác. Ngược lại, với những ảnh có chất lượng thấp, ảnh mờ hoặc đặc trưng bệnh không rõ

ràng, heatmap có thể phân tán hơn và kết quả dự đoán cũng cần được xem xét thận trọng.

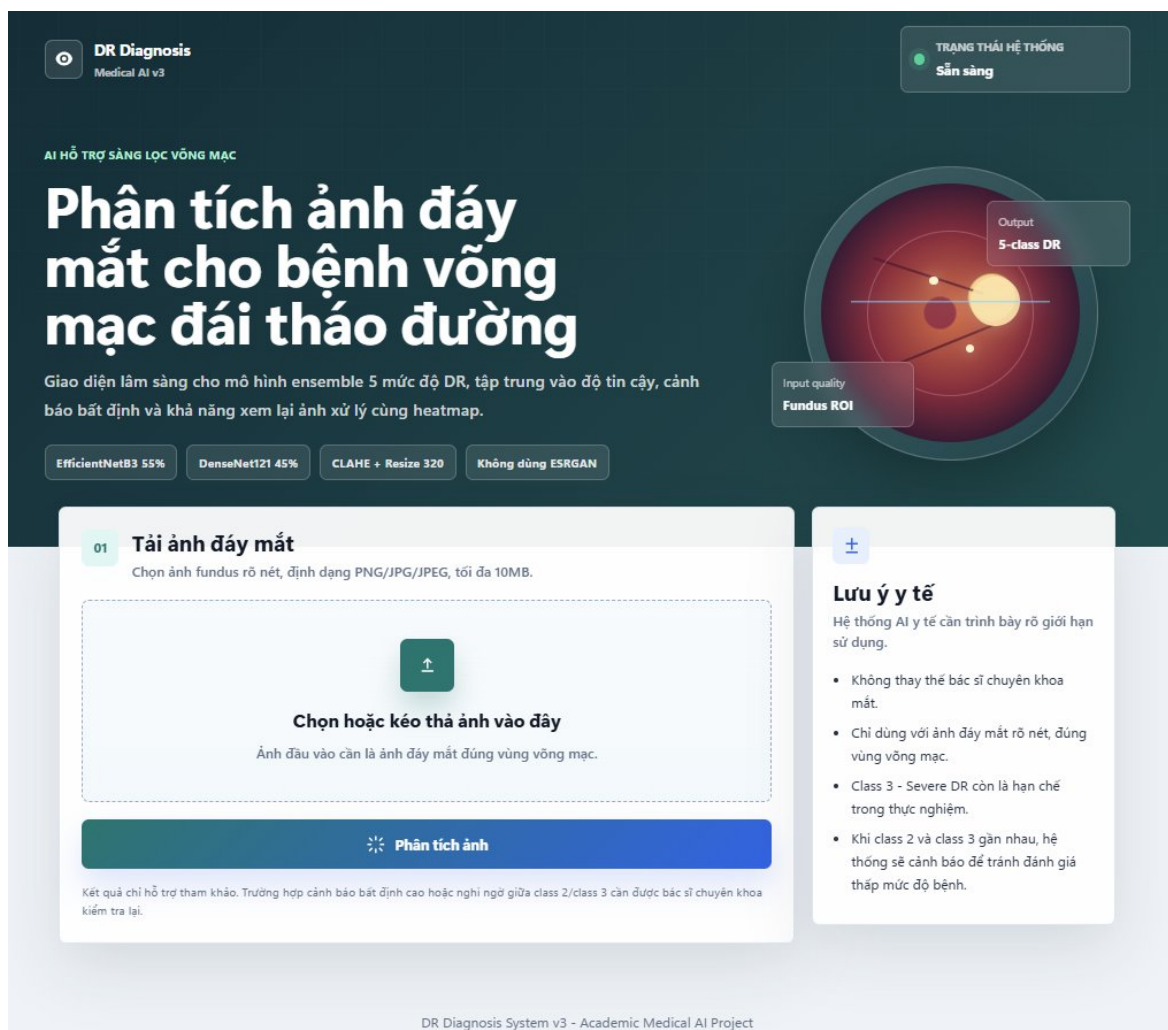
Cần nhấn mạnh rằng heatmap trong đề tài chỉ có vai trò hỗ trợ giải thích kết quả dự đoán của mô hình, không phải là kết quả phân đoạn tổn thương võng mạc. Vùng nổi bật trên heatmap không khẳng định chắc chắn đó là vị trí tổn thương y khoa, mà chỉ cho thấy vùng ảnh có ảnh hưởng nhiều hơn đến quyết định của mô hình. Do đó, heatmap không được sử dụng để xác định chính xác các tổn thương như vi phình mạch, xuất huyết, xuất tiết hay tân mạch. Việc hiển thị heatmap trong hệ thống nhằm tăng tính minh bạch của mô hình và giúp người dùng có thêm thông tin tham khảo, đồng thời kết quả vẫn cần được hiểu là hỗ trợ chứ không thay thế cho đánh giá của bác sĩ chuyên khoa.

Trong phạm vi đề tài, heatmap được xem là một thành phần bổ sung có ý nghĩa khi triển khai mô hình vào hệ thống web. Nếu chỉ hiển thị nhãn dự đoán và xác suất, người dùng khó hình dung mô hình đã xử lý ảnh theo hướng nào. Khi bổ sung heatmap, hệ thống có thể trình bày kết quả theo cách trực quan hơn, gồm ảnh gốc, ảnh sau tiền xử lý, heatmap giải thích, nhãn dự đoán và xác suất từng lớp. Cách trình bày này phù hợp với mục tiêu của đề tài là xây dựng một hệ thống hỗ trợ dự đoán có tính minh họa, giúp người dùng hiểu rõ hơn về kết quả của mô hình nhưng vẫn giữ sự thận trọng cần thiết trong bối cảnh ảnh y tế.

5.5. Kết quả triển khai hệ thống web

Sau khi mô hình ensemble được huấn luyện và lưu lại, đề tài tiến hành tích hợp mô hình vào hệ thống web để kiểm thử quy trình dự đoán trên ảnh đáy mắt mới. Hệ thống được triển khai theo mô hình frontend và backend tách biệt. Frontend được xây dựng bằng React và Vite, có nhiệm vụ cung cấp giao diện cho người dùng tải ảnh và quan sát kết quả. Backend được xây dựng bằng FastAPI, đảm nhiệm việc tiếp nhận ảnh, thực hiện tiền xử lý, gọi mô hình AI để suy luận, sinh heatmap giải thích và trả kết quả về giao diện. Trong phạm vi đề tài, hệ thống được chạy ở môi trường cục bộ nhằm phục vụ kiểm thử và trình bày kết quả nghiên cứu.

Giao diện của hệ thống được thiết kế theo hướng đơn giản, tập trung vào chức năng chính là tải ảnh đáy mắt và hiển thị kết quả dự đoán. Người dùng chọn ảnh từ

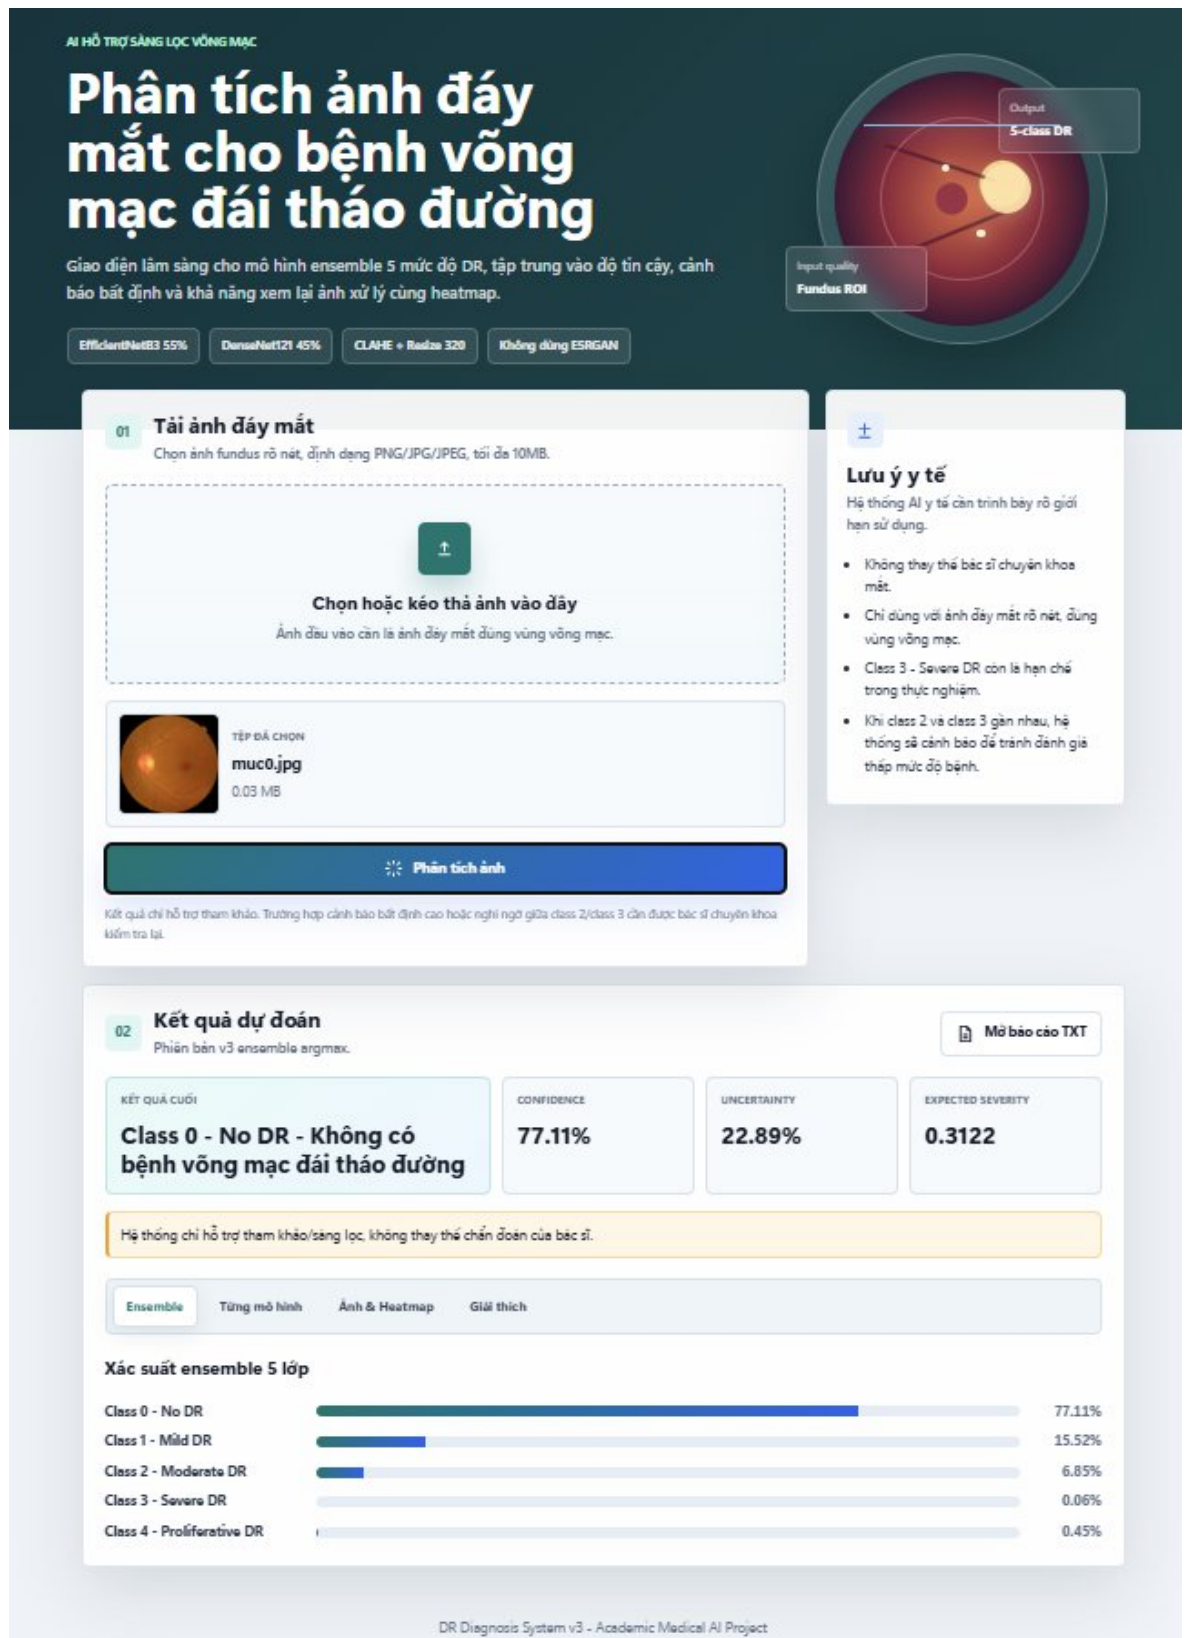


Hình 5. 2. Giao diện tải ảnh đáy mắt của hệ thống.

thiết bị cá nhân, sau đó gửi ảnh lên hệ thống để dự đoán. Khi backend nhận được ảnh, hệ thống thực hiện các bước xử lý giống với quy trình đã sử dụng trong quá trình huấn luyện, gồm cắt vùng viền đen, tăng cường tương phản, resize ảnh về 320×320 và chuẩn hóa dữ liệu đầu vào. Việc giữ thống nhất quy trình tiền xử lý giữa giai đoạn huấn luyện và triển khai giúp hạn chế sự sai lệch giữa dữ liệu mô hình đã học và dữ liệu được đưa vào khi dự đoán thực tế.

Kết quả hiển thị trên giao diện gồm nhãn dự đoán cuối cùng, xác suất dự đoán, xác suất của từng lớp bệnh, ảnh gốc, ảnh sau tiền xử lý và heatmap giải thích. Các thông tin này giúp người dùng không chỉ biết mô hình dự đoán ảnh thuộc mức độ bệnh nào, mà còn quan sát được mức độ chắc chắn của mô hình đối với từng lớp. Việc hiển thị ảnh gốc và ảnh sau tiền xử lý giúp đối chiếu giữa dữ liệu đầu vào ban đầu và dữ liệu thực tế được đưa vào mô hình. Trong khi đó, heatmap giúp trực quan hóa vùng

ảnh có ảnh hưởng đến kết quả dự đoán, qua đó làm cho kết quả của mô hình dễ quan sát hơn so với việc chỉ hiển thị một nhãn phân loại.



Ngoài kết quả dự đoán, hệ thống còn bổ sung cảnh báo y tế trong một số trường hợp cần thiết. Nếu độ tin cậy của mô hình thấp hoặc xác suất giữa các lớp bệnh lân cận gần nhau, hệ thống sẽ hiển thị cảnh báo để người dùng hiểu rằng kết quả cần được xem xét thận trọng. Đặc biệt, cảnh báo giữa Moderate DR và Severe DR được đưa vào do kết quả thực nghiệm cho thấy mô hình còn gặp khó khăn khi phân biệt hai mức bệnh này. Việc bổ sung cảnh báo không làm thay đổi kết quả dự đoán của mô hình, nhưng giúp hệ thống trình bày kết quả có trách nhiệm hơn trong bối cảnh ảnh y tế.

Nhìn chung, hệ thống web đã thực hiện được quy trình dự đoán cơ bản từ ảnh đầu vào đến kết quả đầu ra. Người dùng có thể tải ảnh đáy mắt, hệ thống xử lý ảnh, mô hình ensemble đưa ra kết quả phân loại và giao diện hiển thị kết quả kèm các thông tin hỗ trợ. Việc triển khai hệ thống web cho thấy mô hình AI của đề tài có thể được tích hợp vào một ứng dụng thử nghiệm, qua đó minh họa khả năng ứng dụng của mô hình học sâu trong hỗ trợ phân loại bệnh võng mạc đái tháo đường. Tuy nhiên, hệ thống hiện chỉ dừng ở mức thử nghiệm cục bộ, chưa triển khai trên máy chủ thực tế và chưa được kiểm định trong môi trường lâm sàng.

5.6. Nhận xét chung về kết quả thực nghiệm

Từ các kết quả thực nghiệm, có thể thấy mô hình ensemble giữa DenseNet121 và EfficientNetB3 là phương án cho kết quả tốt nhất trong đề tài. Mô hình đạt accuracy 84,73%, QWK 0,9042, macro-F1 0,7066 và AUC 0,9522 trên tập kiểm tra. So với từng mô hình đơn lẻ, phương pháp ensemble giúp cải thiện nhiều chỉ số quan trọng như QWK, macro-F1 và AUC, cho thấy việc kết hợp hai kiến trúc CNN khác nhau có thể giúp kết quả dự đoán ổn định hơn trong bài toán phân loại bệnh võng mạc đái tháo đường 5 mức độ. Bên cạnh đó, việc phân tích classification report và confusion matrix cho thấy mô hình dự đoán tốt ở lớp No DR và tương đối ổn ở lớp Moderate DR. Tuy nhiên, mô hình vẫn còn hạn chế ở một số lớp ít mẫu hoặc có đặc trưng gần nhau, đặc biệt là lớp Severe DR, khi một số ảnh còn bị nhầm sang Moderate DR hoặc Proliferative DR.

Ngoài kết quả đánh giá mô hình, đề tài cũng đã tích hợp mô hình ensemble vào hệ thống web thử nghiệm để minh họa quy trình dự đoán trên ảnh đáy mắt mới. Hệ thống cho phép người dùng tải ảnh, thực hiện tiền xử lý, dự đoán mức độ bệnh, hiển thị xác suất từng lớp, ảnh gốc, ảnh sau tiền xử lý và heatmap giải thích. Việc bổ sung heatmap và cảnh báo y tế giúp kết quả được trình bày trực quan và thận trọng hơn, đặc biệt trong những trường hợp mô hình chưa chắc chắn giữa các lớp bệnh lân cận như Moderate DR và Severe DR. Nhìn chung, đề tài đã đạt được mục tiêu xây dựng mô hình học sâu hỗ trợ phân loại bệnh võng mạc đái tháo đường và triển khai mô hình vào một hệ thống web thử nghiệm. Tuy vậy, hệ thống vẫn còn một số hạn chế như dữ

liệu huấn luyện chưa thật sự cân bằng, khả năng nhận diện lớp Severe DR chưa cao, heatmap chỉ mang tính giải thích trực quan và hệ thống chưa được kiểm định trong môi trường lâm sàng thực tế.

CHƯƠNG 6

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết quả đạt được

Đề tài đã xây dựng được mô hình học sâu hỗ trợ phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt theo 5 mức độ: No DR, Mild DR, Moderate DR, Severe DR và Proliferative DR. Tập dữ liệu được sử dụng là APTOS 2019, trong đó ảnh đầu vào được tiền xử lý bằng các bước cắt vùng viền đen, tăng cường tương phản bằng CLAHE, resize về kích thước 320×320 và chuẩn hóa trước khi đưa vào mô hình. Trên cơ sở đó, đề tài đã xây dựng và huấn luyện hai mô hình CNN là DenseNet121 và EfficientNetB3, sau đó kết hợp xác suất đầu ra của hai mô hình bằng phương pháp ensemble weighted average. Kết quả thực nghiệm cho thấy mô hình ensemble đạt accuracy 84,73%, QWK 0,9042, macro-F1 0,7066 và AUC 0,9522, cao hơn từng mô hình đơn lẻ ở nhiều chỉ số quan trọng. Điều này cho thấy hướng kết hợp hai mô hình có thể cải thiện độ ổn định của kết quả dự đoán trong bài toán phân loại bệnh võng mạc đái tháo đường nhiều mức độ.

Bên cạnh việc xây dựng mô hình phân loại, đề tài cũng đã tích hợp mô hình vào một hệ thống web thử nghiệm để minh họa quy trình dự đoán trên ảnh đáy mắt mới. Hệ thống cho phép người dùng tải ảnh, thực hiện tiền xử lý, dự đoán mức độ bệnh, hiển thị xác suất từng lớp, ảnh gốc, ảnh sau tiền xử lý và heatmap giải thích. Ngoài ra, hệ thống còn bổ sung cảnh báo trong trường hợp mô hình có độ tin cậy thấp hoặc xác suất giữa các lớp bệnh lân cận gần nhau, đặc biệt là giữa Moderate DR và Severe DR. Như vậy, đề tài không chỉ dừng lại ở việc huấn luyện mô hình mà còn hoàn thiện được một quy trình thử nghiệm từ dữ liệu đầu vào đến kết quả hiển thị trên giao diện, phù hợp với mục tiêu xây dựng hệ thống hỗ trợ tham khảo trong phạm vi nghiên cứu.

6.2. Hạn chế của đề tài

Mặc dù đề tài đã xây dựng được mô hình ensemble và triển khai thử nghiệm trên hệ thống web, kết quả đạt được vẫn còn một số hạn chế nhất định. Trước hết, tập dữ liệu APTOS 2019 có sự mất cân bằng giữa các lớp bệnh, trong đó lớp No DR và Moderate DR có số lượng ảnh nhiều hơn, còn các lớp như Severe DR và Proliferative DR có số lượng ảnh ít hơn. Điều này ảnh hưởng đến khả năng học đặc trưng của mô hình, đặc biệt ở lớp Severe DR. Kết quả thực nghiệm cho thấy mô hình vẫn còn nhầm lẫn giữa Severe DR với Moderate DR và Proliferative DR. Đây là hạn chế quan trọng vì các lớp bệnh nặng có ý nghĩa lớn trong hỗ trợ sàng lọc và cảnh báo nguy cơ. Ngoài ra, dữ liệu trong đề tài chủ yếu được đánh giá trên tập dữ liệu công khai, chưa được

kiểm chứng trên dữ liệu thực tế từ nhiều thiết bị chụp, nhiều cơ sở y tế hoặc nhiều nhóm bệnh nhân khác nhau.

Bên cạnh hạn chế về dữ liệu và kết quả phân loại, hệ thống web trong đề tài mới dừng ở mức thử nghiệm cục bộ, chưa được triển khai trên máy chủ thực tế và chưa được kiểm định trong môi trường lâm sàng. Heatmap được sử dụng để hỗ trợ giải thích kết quả dự đoán, nhưng chỉ có ý nghĩa trực quan, không phải là kết quả phân đoạn tổn thương võng mạc và không thể xác định chính xác các dấu hiệu bệnh lý như vi phình mạch, xuất huyết, xuất tiết hay tân mạch. Vì vậy, kết quả của hệ thống chỉ nên được xem là thông tin hỗ trợ tham khảo, không thay thế cho chẩn đoán của bác sĩ chuyên khoa. Những hạn chế này cho thấy hệ thống vẫn cần được cải thiện thêm về dữ liệu, mô hình, khả năng giải thích và mức độ kiểm chứng thực tế trước khi có thể mở rộng ứng dụng trong môi trường y tế.

6.3. Hướng phát triển trong tương lai

Trong phạm vi khóa luận, đề tài đã xây dựng được mô hình học sâu hỗ trợ phân loại bệnh võng mạc đái tháo đường từ ảnh đáy mắt và tích hợp mô hình vào hệ thống web thử nghiệm. Trong tương lai, đề tài có thể được phát triển theo hướng mở rộng dữ liệu huấn luyện và cải thiện khả năng phân loại ở các lớp bệnh còn dễ nhầm lẫn. Việc bổ sung thêm ảnh đáy mắt từ nhiều nguồn dữ liệu khác nhau, nhiều thiết bị chụp và nhiều điều kiện ảnh khác nhau sẽ giúp mô hình học được đặc trưng đa dạng hơn. Bên cạnh đó, có thể nghiên cứu thêm các kỹ thuật tăng cường dữ liệu hoặc xử lý mất cân bằng phù hợp với ảnh y tế nhằm cải thiện khả năng nhận diện các mức bệnh nặng như Severe DR và Proliferative DR. Về mô hình, có thể tiếp tục tinh chỉnh tham số huấn luyện, thử nghiệm thêm các kiến trúc CNN khác hoặc cải tiến phương pháp ensemble để nâng cao độ ổn định của kết quả dự đoán.

Một hướng phát triển quan trọng khác là mở rộng hệ thống từ bài toán phân loại sang kết hợp phân đoạn hoặc phát hiện tổn thương trên ảnh đáy mắt. Phiên bản hiện tại của đề tài tập trung vào dự đoán mức độ bệnh và sử dụng heatmap để hỗ trợ giải thích vùng ảnh có ảnh hưởng đến kết quả. Trong các nghiên cứu tiếp theo, nếu có tập dữ liệu gán nhãn tổn thương phù hợp, hệ thống có thể được phát triển thêm chức năng phân đoạn các dấu hiệu liên quan đến bệnh võng mạc đái tháo đường như vi phình mạch, xuất huyết, xuất tiết hoặc tân mạch. Khi kết hợp phân loại mức độ bệnh với phân đoạn tổn thương, kết quả trả về sẽ có tính trực quan cao hơn, giúp người dùng không chỉ biết ảnh thuộc mức độ bệnh nào mà còn quan sát được những vùng nghi ngờ trên ảnh. Đây là hướng phát triển có ý nghĩa vì nó giúp hệ thống tiến gần hơn đến vai trò hỗ trợ bác sĩ hoặc nhân viên y tế trong quá trình sàng lọc ban đầu.

Bên cạnh cải thiện mô hình, hệ thống cũng có thể được phát triển theo hướng ứng dụng thực tế hơn trong đời sống. Từ hệ thống web thử nghiệm hiện tại, có thể

mở rộng thành một công cụ hỗ trợ sàng lọc ban đầu tại phòng khám, bệnh viện, trung tâm y tế hoặc các chương trình khám sức khỏe cộng đồng cho người bệnh đái tháo đường. Người dùng hoặc nhân viên y tế có thể tải ảnh đáy mắt lên hệ thống, nhận kết quả dự đoán mức độ bệnh, xem xác suất từng lớp, heatmap giải thích và cảnh báo nếu mô hình chưa chắc chắn. Trong tương lai, hệ thống cũng có thể được tích hợp vào nền tảng quản lý hồ sơ bệnh nhân, ứng dụng tư vấn sức khỏe từ xa hoặc phần mềm hỗ trợ theo dõi định kỳ cho người bệnh đái tháo đường. Khi đó, hệ thống không thay thế bác sĩ mà đóng vai trò như một công cụ hỗ trợ tham khảo, giúp phát hiện sớm các trường hợp có nguy cơ và khuyến nghị người bệnh đi khám chuyên khoa kịp thời hơn.

Đối với phần triển khai, hệ thống web có thể được hoàn thiện thêm bằng cách bổ sung chức năng lưu lịch sử dự đoán, xuất báo cáo kết quả, kiểm tra chất lượng ảnh đầu vào và cải thiện cách trình bày cảnh báo y tế. Nếu được triển khai trên máy chủ hoặc nền tảng điện toán đám mây, hệ thống có thể được truy cập từ nhiều thiết bị khác nhau, giúp việc thử nghiệm và sử dụng trở nên thuận tiện hơn. Tuy nhiên, dù phát triển theo hướng nào, hệ thống vẫn cần giữ vai trò là công cụ hỗ trợ tham khảo, không thay thế cho chẩn đoán của bác sĩ chuyên khoa. Đây là định hướng quan trọng để việc ứng dụng trí tuệ nhân tạo trong phân tích ảnh đáy mắt được thực hiện một cách thận trọng, có trách nhiệm và phù hợp với bối cảnh y tế.

TÀI LIỆU THAM KHẢO

- [1] World Health Organization, “Promoting diabetic retinopathy screening,” World Health Organization.
- [2] World Health Organization, *Diabetic Retinopathy Screening: A Short Guide*. WHO Regional Office for Europe, 2020.
- [3] International Diabetes Federation, “Viet Nam diabetes report 2011–2050,” *IDF Diabetes Atlas*, 2024.
- [4] International Diabetes Federation, “Diabetes facts & figures,” International Diabetes Federation, 2024.
- [5] C. P. Wilkinson, F. L. Ferris III, R. E. Klein, P. P. Lee, C. D. Agardh, M. Davis, D. Dills, A. Kampik, R. Pararajasegaram, and J. T. Verdaguer, “Proposed international clinical diabetic retinopathy and diabetic macular edema disease severity scales,” *Ophthalmology*, vol. 110, no. 9, pp. 1677–1682, 2003.
- [6] M. E. P. Solomon, E. Chew, E. J. Duh, L. Sobrin, J. K. Sun, B. L. VanderBeek, C. C. Wykoff, and T. W. Gardner, “Diabetic retinopathy: A position statement by the American Diabetes Association,” *Diabetes Care*, vol. 40, no. 3, pp. 412–418, 2017.
- [7] T. Y. Wong, C. M. G. Cheung, M. Larsen, S. Sharma, and R. Simó, “Diabetic retinopathy,” *Nature Reviews Disease Primers*, vol. 2, Article 16012, 2016.
- [8] R. Klein, B. E. K. Klein, S. E. Moss, M. D. Davis, and D. L. DeMets, “The Wisconsin Epidemiologic Study of Diabetic Retinopathy,” *Archives of Ophthalmology*, 1984.
- [9] Kaggle, “APTOS 2019 Blindness Detection,” Kaggle Competition, 2019.
- [10] Kaggle, “Diabetic Retinopathy Detection,” Kaggle Competition, 2015.
- [11] E. Decencière et al., “Feedback on a publicly distributed image database: The Messidor database,” *Image Analysis & Stereology*, vol. 33, no. 3, pp. 231–234, 2014.
- [12] P. Porwal et al., “Indian Diabetic Retinopathy Image Dataset (IDRiD): A database for diabetic retinopathy screening research,” *Data*, vol. 3, no. 3, Article 25, 2018.
- [13] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, pp. 436–444, 2015.
- [14] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems*, 2012.

- [15] J. Deng, W. Dong, R. Socher, L. J. Li, K. Li, and L. Fei-Fei, “ImageNet: A large-scale hierarchical image database,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2009.
- [16] O. Russakovsky et al., “ImageNet Large Scale Visual Recognition Challenge,” *International Journal of Computer Vision*, vol. 115, pp. 211–252, 2015.
- [17] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” in *International Conference on Learning Representations*, 2015.
- [18] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016.
- [19] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [20] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proceedings of the 36th International Conference on Machine Learning*, 2019.
- [21] C. Szegedy et al., “Going deeper with convolutions,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2015.
- [22] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional networks for biomedical image segmentation,” in *Medical Image Computing and Computer-Assisted Intervention*, 2015.
- [23] S. M. Pizer et al., “Adaptive histogram equalization and its variations,” *Computer Vision, Graphics, and Image Processing*, vol. 39, no. 3, pp. 355–368, 1987.
- [24] K. Zuiderveld, “Contrast limited adaptive histogram equalization,” in *Graphics Gems IV*, Academic Press, pp. 474–485, 1994.
- [25] C. Shorten and T. M. Khoshgoftaar, “A survey on image data augmentation for deep learning,” *Journal of Big Data*, vol. 6, Article 60, 2019.
- [26] S. Yang, W. Xiao, M. Zhang, S. Guo, J. Zhao, and F. Shen, “Image data augmentation for deep learning: A survey,” arXiv preprint arXiv:2204.08610, 2022.
- [27] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE: Synthetic minority over-sampling technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.

- [28] J. Cohen, “Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit,” *Psychological Bulletin*, vol. 70, no. 4, pp. 213–220, 1968.
- [29] T. Fawcett, “An introduction to ROC analysis,” *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.
- [30] M. Sokolova and G. Lapalme, “A systematic analysis of performance measures for classification tasks,” *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009.
- [31] D. M. W. Powers, “Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation,” *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, 2011.
- [32] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE International Conference on Computer Vision*, 2017.
- [33] M. Sundararajan, A. Taly, and Q. Yan, “Axiomatic attribution for deep networks,” in *Proceedings of the 34th International Conference on Machine Learning*, 2017.
- [34] M. T. Ribeiro, S. Singh, and C. Guestrin, “‘Why should I trust you?’ Explaining the predictions of any classifier,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [35] W. Samek, T. Wiegand, and K. R. Müller, “Explainable artificial intelligence: Understanding, visualizing and interpreting deep learning models,” arXiv preprint arXiv:1708.08296, 2017.
- [36] V. Gulshan et al., “Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs,” *JAMA*, vol. 316, no. 22, pp. 2402–2410, 2016.
- [37] D. S. W. Ting et al., “Development and validation of a deep learning system for diabetic retinopathy and related eye diseases using retinal images from multiethnic populations with diabetes,” *JAMA*, vol. 318, no. 22, pp. 2211–2223, 2017.
- [38] M. D. Abràmoff, P. T. Lavin, M. Birch, N. Shah, and J. C. Folk, “Pivotal trial of an autonomous AI-based diagnostic system for detection of diabetic retinopathy in primary care offices,” *npj Digital Medicine*, vol. 1, Article 39, 2018.

- [39] Y. Yang, T. Li, W. Li, H. Wu, W. Fan, and W. Zhang, "Lesion detection and grading of diabetic retinopathy via two-stages deep convolutional neural networks," arXiv preprint arXiv:1705.00771, 2017.
- [40] S. M. S. Islam, M. M. Hasan, and S. Abdullah, "Deep learning based early detection and grading of diabetic retinopathy using retinal fundus images," arXiv preprint arXiv:1812.10595, 2018.
- [41] B. Tymchenko, P. Marchenko, and D. Spodarets, "Deep learning approach to diabetic retinopathy detection," arXiv preprint arXiv:2003.02261, 2020.
- [42] J. Zhang, B. Xie, X. Wu, R. Ram, and D. Liang, "Classification of diabetic retinopathy severity in fundus images with DenseNet121 and ResNet50," arXiv preprint arXiv:2108.08473, 2021.
- [43] M. delaPava, H. Ríos, F. J. Rodríguez, O. J. Perdomo, and F. A. González, "A deep learning model for classification of diabetic retinopathy in eye fundus images based on retinal lesion detection," arXiv preprint arXiv:2110.07745, 2021.
- [44] G. Alwakid, W. Gouda, M. Humayun, and N. Z. Jhanjhi, "Deep learning-based prediction of diabetic retinopathy using retinal fundus images," *Healthcare*, vol. 11, no. 6, Article 863, 2023.
- [45] S. Ghosh and A. Chatterjee, "Transfer-ensemble learning based deep convolutional neural networks for diabetic retinopathy classification," arXiv preprint arXiv:2308.00525, 2023.
- [46] H. Shakibania, S. Raoufi, B. Pourafkham, H. Khotanlou, and M. Mansoorizadeh, "Dual branch deep learning network for detection and stage grading of diabetic retinopathy," *Biomedical Signal Processing and Control*, vol. 93, Article 106168, 2024.
- [47] S. V. Chilukoti et al., "A reliable diabetic retinopathy grading via transfer learning and ensemble learning with quadratic weighted kappa metric," *Scientific Reports*, 2024.
- [48] L. Arora et al., "Ensemble deep learning and EfficientNet for accurate diabetic retinopathy detection," *Scientific Reports*, 2024.
- [49] D. Dharrao et al., "AI-driven detection and classification of diabetic retinopathy using fundus images and Grad-CAM heatmaps," *Discover Applied Sciences*, 2025.
- [50] S. Mardianta, Affandy, C. Supriyanto, and A. Wijaya, "Diabetic retinopathy detection based on convolutional neural networks with SMOTE and CLAHE techniques applied to fundus images," arXiv preprint arXiv:2504.05696, 2025.

- [51] A. Hannan, Z. Mahmood, R. Qureshi, and H. Ali, “Enhancing diabetic retinopathy classification accuracy through dual attention mechanism in deep learning,” arXiv preprint arXiv:2507.19199, 2025.
- [52] M. Youldash, A. Rahman, M. Alsayed, A. Sebiany, J. Alzayat, N. Aljishi, G. Alshammari, and M. Alqahtani, “Deep learning empowered diagnosis of diabetic retinopathy,” *Intelligent Automation & Soft Computing*, vol. 40, no. 1, pp. 125–143, 2025.
- [53] F. Ahmed, “Addressing high class imbalance in multi-class diabetic retinopathy severity grading with augmentation and transfer learning,” arXiv preprint arXiv:2507.17121, 2025.
- [54] M. Youldash et al., “Early detection and classification of diabetic retinopathy: A deep learning approach,” *AI*, vol. 5, no. 4, pp. 2586–2617, 2024.
- [55] A. Minarno, A. Bagaskara, F. Bimantoro, and W. Suharso, “Classification of diabetic retinopathy based on fundus image using InceptionV3,” *JOIV: International Journal on Informatics Visualization*, vol. 9, no. 1, pp. 23–28, Jan. 2025.